


DEL CAOS A LA PRODUCCIÓN


Ingeniería del Conocimiento: Dominando el Aprendizaje No Supervisado y el Despliegue de Sistemas ML.



[BLOQUE 1: CLUSTERING]

[BLOQUE 2: DESPLIEGUE]

Aprendizaje Supervisado



Objetivo: Predecir clase conocida a partir de etiquetas previas.

Aprendizaje No Supervisado



Objetivo: Descubrir estructura oculta basada puramente en la similitud matemática.


⚠ El Motor de la Similitud

El clustering agrupa calculando distancias (Euclidiana, Manhattan). Si un feature está en miles (salario) y otro en unidades (edad), la distancia colapsa. **Regla #1: Siempre estandarizar.**

```
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

K-MEANS: El Estándar Geométrico


1. Inicialización



Se eligen 'K' **centroides iniciales** (K-Means++ optimiza este paso).

2. Asignación


Cada dato es atraído magnéticamente al centroide más cercano.



Iteración
hasta
estabilidad


4. Convergencia

Estabilidad total. Ningún punto cambia de grupo.



3. Actualización

Los centroides se recalculan y se mueven a la media exacta de su grupo.



El Arte de Elegir 'K' y la Trampa de la Forma

El Diagnóstico (Buscando K)

Método del Codo (Inercia / WCSS)




Coefficiente de Silueta




Buscamos el codo en la inercia y el pico máximo en la silueta.

La Limitación de K-Means

K-Means (Fallo)




DBSCAN (Éxito)



K-Means asume clusters estrictamente esféricos y de tamaño similar. Cuando la geometría se vuelve compleja, fracasa.

DBSCAN: Crecimiento Orgánico por Densidad


No requiere 'K'. Se adapta a cualquier forma. Aísla valores atípicos.



Buscando eps (K-Distancias)



Aglomerativo: Construyendo Jerarquías



Criterios de Enlace (Linkage)

Single



Mínima distancia.
Crea encadenamiento.

Complete



Máxima distancia.
Crea clusters compactos.

Ward (Por Defecto)




Minimiza la varianza interna.

GMM: El Enfoque Probabilístico


Cuando un punto pertenece a múltiples grupos al mismo tiempo.

K-Means: Asignación Dura



Fronteras rígidas (Hard clustering).
Eres A o B, sin matices.

GMM: Asignación Suave



Modela la incertidumbre. Superposición y **probabilidades** (Soft clustering).

Telemetría: Midiendo lo Invisible

¿Cómo medimos el éxito si no tenemos 'respuestas correctas'?

Métricas Internas (Cuando no hay etiquetas)

1

Silhouette Score



Cohesión vs Separación

2

Calinski-Harabasz



Varianza (Mayor = Mejor)

3

Davies-Bouldin



Similitud inter-cluster (Menor = Mejor)

Métricas Externas (Con etiquetas de validación)

1

ARI (Adjusted Rand Index)



0.85

2

NMI (Normalized Mutual Info)



0.92

En la vida real, casi nunca tenemos etiquetas. Las métricas internas son nuestra única brújula.

La Matriz Diagnóstica del Clustering

Hoja de trucos: Cuándo usar qué algoritmo en ingeniería de sistemas.

[Algoritmo]	[¿Requiere 'K'?]	[Forma Asumida]	[Tolerancia al Ruido]	[Caso de Uso Ideal]
K-Means	Sí	Esférica	Baja (Sensible a outliers)	General, segmentación rápida, compresión.
DBSCAN	No	Cualquiera	Alta (Clasifica como -1)	Detección de anomalías, geometrías complejas.
Jerárquico	No (Corte a posteriori)	Depende del Linkage	Baja	Taxonomías, biología, descubrimiento visual.
GMM	Sí	Elíptica	Baja	Incertidumbre, clusters superpuestos.

El Abismo del Despliegue

El Laboratorio (Data Science)




Entorno local.
Datos estáticos.
Scikit-learn.

El Mundo Real (Producción)



Usuarios reales.
Datos impredecibles.
Internet.




**Entrenar el modelo es solo el 50% del trabajo.
Tu cliente no usa Jupyter Notebooks. Construyamos sistemas.**

Serialización y el Secreto del Pipeline

El error de novato más común: olvidar estandarizar en producción.

❌ El Error Clásico



Exportar solo el modelo matemático.
Los nuevos datos colapsan el sistema.

```
import joblib
joblib.dump(pipeline, 'modelo.joblib')
```

✅ La Práctica de Ingeniería




Empaquetar el preprocesamiento y el
cerebro como un solo objeto sellado.

```
import joblib
pipeline_prod = joblib.load('modelo.joblib')
```

Flask: Tu Modelo como una API REST

Exponiendo conocimiento matemático a la web.



FastAPI: El Estándar Moderno


Velocidad asíncrona, validación nativa y documentación automática.

Validación Estricta (Pydantic)

```
1 class InputData(BaseModel):
2     features: list[float]
3
4 @app.post('/predict')
5 def predict(data: InputData):
6     return model.predict(data.features)
```

 **Garantiza que la API no colapse si un usuario envía texto en lugar de números. Tipado estático en Python.**

Documentación Automática (/docs)



 **Genera interfaces de prueba interactivas instantáneamente, un deleite para ingenieros de frontend.**

Gradio: Democratizando la Interfaz

Crea prototipos interactivos en minutos para validar con clientes. Cero HTML/CSS.

El Código (5 líneas)

```
1 import gradio as gr
2
3 demo = gr.Interface(
4     fn=predecir,
5     inputs=[gr.Slider(0, 10), gr.Number()],
6     outputs='text'
7 )
8 demo.launch()
```

El Resultado Visual



Predictor ML

Ingreso Medio 5.4

Antigüedad


12

PREDECIR

Precio estimado: \$345,000

The Blueprint: Del Dato al Usuario

El ciclo de vida completo de un sistema de Machine Learning.



**“No construimos modelos para que vivan en notebooks.
Construimos sistemas para resolver problemas.”**