




Entendiendo la Regresión Supervisada con scikit-learn

Desde trazar la primera línea hasta orquestar pipelines profesionales.
Un manual paso a paso para la construcción de modelos.



PIPELINE PROFESIONAL



La Idea Central: ¿Qué significa predecir un número?

No estamos adivinando etiquetas discretas. Estamos calculando valores continuos reales.
El reto arquitectónico de hoy: Predecir el precio exacto de una casa en California.

✗ Clasificación



✓ Regresión



ooo

Diccionario de Ingeniería

X (Features) : Información de entrada (Área en m², habitaciones, antigüedad).
y (Target) : Valor real que queremos predecir (Precio en \$USD).
 $\hat{y}$ (y-hat) : Nuestra predicción (El cálculo matemático de nuestro modelo).

El Modelo Fundamental: Regresión Lineal Múltiple

ooo

Concepto: El modelo traza la recta (o hiperplano) que mejor atraviesa nuestros datos, asumiendo que cada variable suma o resta valor de forma independiente.




El precio final
estimado de la casa.


$$\hat{y} = w_0 + w_1 \cdot x_1 + w_2 \cdot x_2$$



Pendiente 2: Por cada habitación extra (x_2), sumamos S/ 12,000.



Intercepto:
El precio base. Lo que cuesta el terreno vacío si todo lo demás fuera 0.




Pendiente 1:
Por cada metro cuadrado extra (x_1), el precio sube S/ 1,500.


¿Cómo 'aprende' realmente el modelo?

El modelo no adivina; optimiza. Busca mecánicamente los parámetros que el mecánicamente los parámetros que generen el mínimo error posible.

The Problem (Residuos)



The Solution (Optimización / OLS)




ooo

¿Por qué elevar al cuadrado?

1. Elimina los signos negativos.
2. Castiga severamente los errores más grandes (los vuelve exponenciales).
3. Crea una curva suave que es matemáticamente fácil de derivar (optimizar).

Nuestro Dashboard de Métricas de Calidad

RMSE (Raíz del MSE)



Interpretación: Me equivoco, en promedio, por X dólares.

Advertencia: Altamente sensible a valores atípicos (outliers) debido al cuadrado.

MAE (Error Absoluto Medio)



Interpretación: La desviación típica, sin exagerar el castigo a los errores grandes.

Robusto y fácil de explicar a negocio.

R^2 (Coef. de Determinación)



Rango: de 0 a 1.

Interpretación: Mi modelo explica el 80% de la variación total en los precios de las casas.

R^2 Ajustado




Pro-Tip: El R^2 normal 'hace trampa' subiendo falsamente si le metes basura. El ajustado aplica una penalización mecánica por añadir variables irrelevantes.


Cuando el mundo real no es recto (Regresión Polinómica)

A veces el precio se estanca aunque el área crezca. La solución: elevamos nuestros features al cuadrado (x^2) o al cubo (x^3).

Fallo Estructural



Adaptación Polinómica




Nota de Ingeniería: ¡Sigue siendo un modelo lineal bajo el capó! Solo estamos engañando al modelo dándole features transformados geoméricamente.

```
make_pipeline(PolynomialFeatures(degree=2), LinearRegression())
```

El Enemigo Público #1: El Sobreajuste (Overfitting)

Subajuste (Sesgo Alto)



Estructura muy simple.
Error alto en Train y Test.

Buen Ajuste



Captura el patrón real,
ignora el ruido aleatorio.

Sobreajuste (Varianza Alta)




El modelo 'memoriza' los datos.
Fracasará terriblemente en producción.
Error bajo en Train, altísimo en Test.

La Ecuación del Error:

$$\text{Error} = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido Irreducible}$$

Refuerzo Estructural: La Regularización

¿Qué es? Añadimos una penalización mecánica por complejidad a nuestra función de costo.




El tensor alpha (α):
Es el hiperparámetro que dicta cuánta fuerza de tracción usamos.

Mucha fuerza =
coeficientes más
pequeños = modelo
más simple y estable.

Minimizar [Error en datos + ($\alpha \times$ **Penalización**)]

El Cuadro Diagnóstico: Ridge vs. Lasso vs. ElasticNet

Ridge (L2)	Lasso (L1)	ElasticNet (L1+L2)
 La Apisonadora. Encoge todos los coeficientes hacia cero, pero nunca los apaga. Penaliza $\sum w^2$. Uso: Ideal para datos con multicolinealidad.	Antigüedad = 0  El Bisturí. Fuerza a que coeficientes irrelevantes sean exactamente CERO. Penaliza $\sum w$. Hace selección automática de variables.	 El Híbrido. Combina ambos mundos usando ambos tipos de penalización. Uso: Cuando tienes muchísimas variables y están altamente correlacionadas.

La Sabiduría de las Multitudes: Modelos de Ensamble

The Problem_{mm}




Árbol de Decisión Simple

Frágil / Overfittea muy rápido.


The Solution

Random Forest (Paralelo)



Entrena cientos de árboles en paralelo con sub-muestras.
Promedia sus respuestas. Altamente robusto.

Gradient Boosting (Secuencial)



Cada nuevo árbol se dedica exclusivamente a corregir los errores matemáticos del árbol anterior.

Pro-Tip: ¿Dataset gigante (>10k registros)? Usa HistGradientBoostingRegressor.

Cómo Trabajan los Profesionales: Pipelines

El Error Novato: Escalar antes de dividir




La Forma Profesional: make_pipeline



```
pipe = make_pipeline(StandardScaler(), Ridge(alpha=1.0))  
pipe.fit(X_train, y_train)
```


Certificando el Modelo: Validación Cruzada (CV)

Un solo train_test_split es cuestión de suerte. Necesitamos rigor de ingeniería.



Interpretabilidad: ¿Qué importa realmente?

Como ingenieros, no basta con predecir con precisión; debemos explicar a negocio por qué sucede.



Ejemplo Real (California Housing)

El 'MedInc' (Ingreso medio del barrio) es, por mucho, el predictor más fuerte del precio de la casa, superando con creces a la antigüedad o habitaciones.

¿Cómo se mide mecánicamente?

- ✓ **Modelos Lineales:** Si los datos están estandarizados, el tamaño absoluto del coeficiente (w) indica el peso real.
- ✓ **Árboles/Ensamblados:** Miden matemáticamente cuánta impureza redujo cada feature en todas sus divisiones internas.

La Guía Rápida de Selección (Cheat Sheet)

¿Qué modelo uso? Un árbol de decisión para el ingeniero de datos.



Conclusión: De la Teoría a la Práctica

Has pasado de trazar una simple recta a orquestar ensambles paralelos con validación cruzada. La regresión no es solo matemática abstracta; es pura ingeniería de datos.



Tu turno (Próximos pasos):

- ✓ 1. Abre un Jupyter Notebook vacío.
- ✓ 2. Carga `fetch_california_housing()`.
- ✓ 3. Construye un `make_pipeline` con `StandardScaler` y `Ridge`.
- ✓ 4. Mide tu R^2 utilizando `cross_val_score`.

`print("Obra certificada. Lista para producción.")`