

Modelos de Regresión: De la Teoría a la Práctica

— El Eje Central de la Predicción Continua —


Asignatura: Ingeniería del Conocimiento (IS056B) — Semana 03

Docente: Msc. Jaime Antonio Huaytalla Pariona

Facultad de Ingeniería de Sistemas, UNCP | Semestre 2026-II

Modelar una función $f: \mathbb{R}^d \rightarrow \mathbb{R}$ que aproxima la relación entre un vector de características $\mathbf{x}$ y una salida continua y .

Conceptual Visual



Notation Matrix

$\mathbf{X}$	Matriz de diseño ($\mathbf{n} \times \mathbf{d}$) -> Dimensiones Críticas: $\mathbf{n}$ filas (observaciones), $\mathbf{d}$ columnas (features)
$\mathbf{y}$	Vector respuesta ($\mathbf{n} \times \mathbf{1}$)
$\mathbf{w}$ o $\boldsymbol{\theta}$	Vector de pesos ($\mathbf{d} \times \mathbf{1}$)
$\hat{\mathbf{y}} = \mathbf{h}(\mathbf{x})$	Predicción del modelo
α o λ	Hiperparámetro de regularización

Motor Matemático

Función de Hipótesis:

$$h_{\theta}(\mathbf{x}) = \boldsymbol{\theta}^T \mathbf{x}$$


Costo (MSE):

$$J(\boldsymbol{\theta}) = \frac{1}{2} (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

Ecuación Normal (Exacta):

$$\boldsymbol{\theta}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Topología de Optimización




Consola de Implementación


```
model = LinearRegression(  
    fit_intercept=True)  
  
model.fit(X, y)
```

Sklearn no invierte $\mathbf{X}^T \mathbf{X}$
(Complejidad $\mathcal{O}(n \cdot d^3)$).
Usa Descomposición SVD
($\mathcal{O}(n \cdot d^2)$) para garantizar
la estabilidad numérica.


Grado 1 (Underfitting)



Grado 3 (Ajuste Óptimo)



Grado 15 (Overfitting)



Motor Matemático

Lineal en parámetros θ , No-lineal en características x .

Transformación de $\{x_1, x_2\}$ a grado 2:
 $\{x_1, x_2, x_1^2, x_1x_2, x_2^2\}$

Consola de Implementación

```
make_pipeline(PolynomialFeatures(degree=3),  
              LinearRegression())
```




¡Peligro de Explosión Dimensional! El crecimiento de características es combinatorio. Memorizar el ruido destruye la generalización.

EL EJE CENTRAL: DESCOMPOSICIÓN SESGO-VARIANZA



Alto Sesgo, Baja Varianza
(Underfitting)




Bajo Sesgo, Alta Varianza
(Overfitting)


$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Sesgo}^2 + \text{Varianza} + \sigma^2 \text{ (Ruido irreducible)}$$

COMPARACIÓN VISUAL: OLS VS. RIDGE (L2)

OLS Sin Restricciones



Restricción Ridge (L2)



MOTOR MATEMÁTICO

$$\min_{\mathbf{w}} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \alpha \|\mathbf{w}\|^2$$

CONCLUSIONES CLAVE

- Mecanismo: Encoge (shrinks) coeficientes de forma proporcional.
- $\mathbf{X}^T\mathbf{X} + \alpha\mathbf{I}$ siempre es invertible (resuelve multicolinealidad).
- Prior Bayesiano: Asume que pesos $\sim N(0, \tau^2\mathbf{I})$.


CONSOLA DE CÓDIGO

```
RidgeCV(alphas=np.logspace(-3, 3, 10))
```


El hiperparámetro α controla el radio del círculo restrictivo.

COMPARACIÓN VISUAL: OLS VS. LASSO (L1)

OLS Sin Restricciones



Restricción Lasso (L1) $\rightarrow w_2 = 0$



MOTOR MATEMÁTICO

$$\min_w \frac{1}{2n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 + \alpha \|\mathbf{w}\|_1$$

CONCLUSIONES CLAVE

- Mecanismo (Soft-Thresholding):
 $w_j = \text{sign}(w_{\text{OLS}}) \cdot \max(|w_{\text{OLS}}| - \alpha, 0)$.
- Fuerza coeficientes a exactamente cero (Sparsity).
- Prior Bayesiano: Distribución de Laplace.

CONSOLA DE CÓDIGO

```
lasso = LassoCV(cv=5)  
eliminadas = np.sum(lasso.coef_ == 0)
```


RESUMEN FINAL: ELASTIC NET Y LA MATRIZ MAESTRA

L1 (Selección) + L2 (Agrupamiento)

Combina $\alpha \cdot l1_ratio \cdot ||w||_1$ y la restricción L2 para resolver la selección arbitraria del Lasso.

Modelo	Penalización	Sparsity (Coef=0)	Multicolinealidad	Prior Bayesiano	Caso de Uso Ideal
OLS	Ninguna	No	Inestable	Plano	$d \ll n$, baseline simple
Ridge	L2 ($\alpha w ^2$)	No	Muy Estable	Gaussiano	Multicolinealidad, todos importan
Lasso	L1 ($\alpha w _1$)	Sí	Arbitraria	Laplaciano	Selección de features, alta dimensionalidad
Elastic Net	L1 + L2	Sí	Efecto Grupo	Combinado	Estándar industrial para modelos lineales robustos

BAGGING (ENSAMBLADO EN PARALELO)



LOS 2 MECANISMOS DE ALEATORIEDAD

1. **Bootstrap Sampling** (muestreo con reemplazo).
2. **Feature Subsetting** aleatorio por nodo (típicamente $m = d/3$).


CONSOLA DE CÓDIGO

```
RandomForestRegressor(max_features='sqrt', oob_score=True, n_jobs=-1)
```

MÉTRICAS INHERENTES

- **Out-of-Bag (OOB) Score:** ~37% de datos no vistos actúan como validación gratuita.
- **Feature Importance (MDI):** Mide la reducción de varianza por variable.

CONSTRUCCIÓN SECUENCIAL (BOOSTING)



MOTOR MATEMÁTICO

Actualización:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

Pseudo-residuos:

$$\text{Ajustando a } r_{im} = -\frac{\partial L(y_i, F_{m-1}(x_i))}{\partial F_{m-1}(x_i)}$$

SHRINKAGE / LEARNING RATE

El parámetro ν (Learning Rate) actúa como regularización. Un ν pequeño requiere más árboles, pero **generaliza mejor**.

FUNCIONES DE PÉRDIDA


Soporta **squared_error**, **huber** (robusto a outliers), **quantile** (intervalos de predicción).

CONSOLA DE CÓDIGO

```
GradientBoostingRegressor(learning_rate=0.05, loss='huber')
```

HISTOGRAM-BASED GRADIENT BOOSTING (BINNING)

TRANSFORMACIÓN VISUAL: BINNING



VENTAJAS DE HISTGRADIENTBOOSTING

- ⚙️ **Velocidad Extrema** (Inspirado en LightGBM).
- ⚠️ **Soporte Nativo NaN** (Sin imputación previa).
- 🌲 **Features Categóricas** (Sin One-Hot Encoding).
- 🛑 **Early Stopping** incorporado.

CONSOLA DE CÓDIGO

```
HistGradientBoostingRegressor(  
    max_bins=255,  
    early_stopping=True  
)
```

MSE & RMSE (Optimización)

Fórmula: $\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$

Impacto: Alta penalización a **outliers**.
RMSE está en unidades del **target**.
Estándar de la industria para entrenar.

MAE (Interpretabilidad de Negocio)

Fórmula: $\frac{1}{n} \sum |y_i - \hat{y}_i|$

Impacto: Robusto a outliers. Ideal para explicar el error a la gerencia
("Nos equivocamos por X en promedio").

R² (Varianza Explicada)

Fórmula: $1 - \frac{SS_{res}}{SS_{tot}}$

Impacto: Escala **0 a 1**. ¿Qué tanto mejor es el modelo en comparación con predecir siempre la media?

R² Ajustado (Selección de Features)

Fórmula: $1 - \left[\frac{(1 - R^2)(n - 1)}{(n - d - 1)} \right]$


Impacto: Penaliza fuertemente la adición de **variables "basura"** para inflar el R².

CONSOLA DE CÓDIGO

```
from sklearn.metrics import root_mean_squared_error, mean_absolute_error, r2_score
```


MODEL DIAGNOSTICS (X-RAY)

RESIDUOS VS PREDICCIONES




Patrón de embudo = **heterocedasticidad**.
Patrón curvo = relación no lineal faltante.

QQ-PLOT



Verifica normalidad. Las desviaciones en las colas indican valores atípicos severos (**outliers**).


CURVAS DE APRENDIZAJE



Brecha gigante = **Varianza (Overfitting)**.
Cierre apretado y alto = **Sesgo (Underfitting)**.

CONSOLA DE CÓDIGO

```
scipy.stats.probplot(residuos, dist='norm')  
sklearn.model_selection.learning_curve(model, X, y)
```



Definir Problema

¿Importa supremamente la interpretabilidad?

SÍ

NO

SÍ

¿Hay Multicolinealidad?

NO

Ridge o Elastic Net

¿Necesita Selección de Features?

SÍ

NO

Lasso o Elastic Net

Regresión OLS

SÍ

¿Dataset gigante (>10K), Nulos y Categóricos?

NO

HistGradientBoosting

¿Las relaciones son muy complejas/no lineales?

SÍ

NO

Gradient Boosting

Random Forest (Baseline general)

DATASETS CLAVE



California Housing
(Regresión &
Regularización)



Ames Housing
Kaggle
(Feature
Engineering)




Diabetes
(Modelos Lineales
Básicos)

BIBLIOGRAFÍA CANÓNICA



Hastie et al.
(ESL/ISLP) - Teoría
Estadística



**Géron (Hands-on
ML)** - Práctica e
Implementación



**Tibshirani (1996) /
Breiman (2001)** -
Papers Seminales

PRÓXIMOS PASOS

- **Laboratorio:** Implementación del flujo Ridge vs Lasso en Jupyter Notebook usando California Housing.
- **Semana 04:** Transición a Aprendizaje No Supervisado (Clustering) y preparación para Despliegue en Producción.