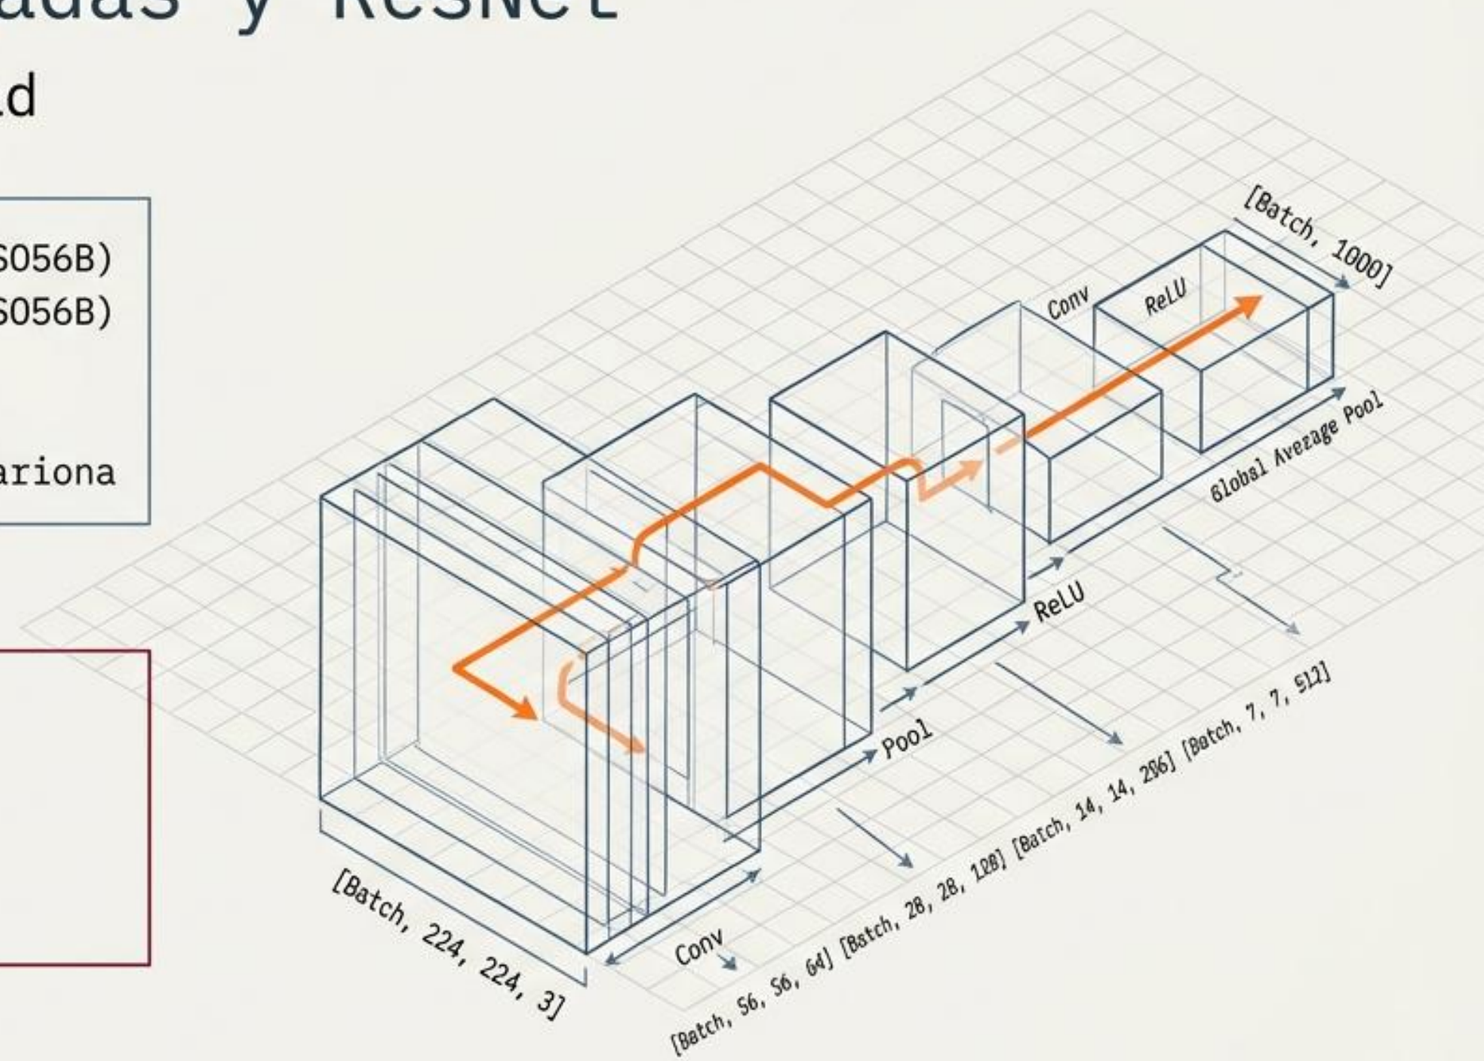
# Redes Neuronales Convolocionales: Arquitecturas Avanzadas y ResNet

## La Búsqueda de la Profundidad

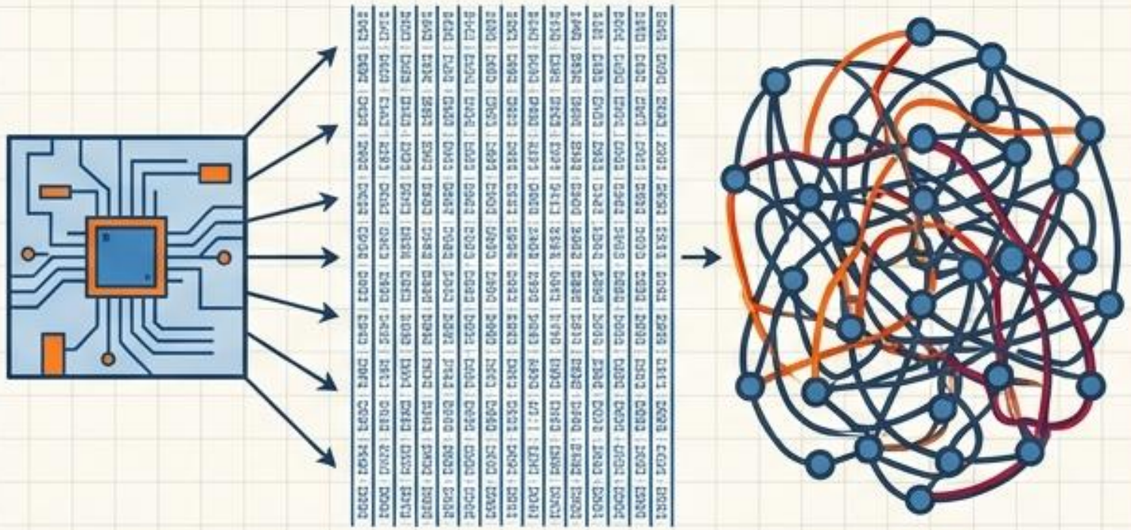
**Asignatura:** Ingeniería del Conocimiento (ISO56B)
**Programa:** Ingeniería del Conocimiento (ISO56B)
**Programa:** Ingeniería de Sistemas – UNCP
**Nivel:** Pregrado (Intermedio-Avanzado)
**Docente:** Msc. Jaime Antonio Huaytalla Pariona

**Requisito ISO46B completado:**
Fundamentos de Redes Neuronales (MLP, Backpropagation) asimilados. Iniciando procesamiento de tensores espaciales.



# EL COLAPSO ESTRUCTURAL DEL MLP

## El Problema de Explosión



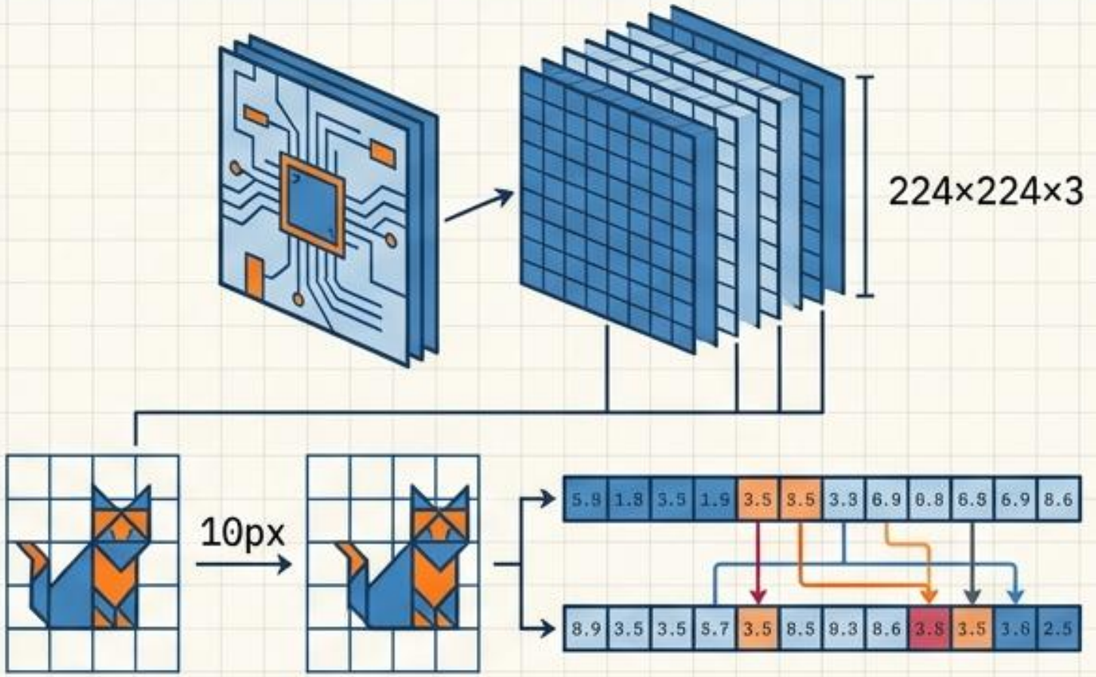
**Input:** 224×224×3 píxeles = 150,528 valores.

**150,528 × 1,000 neuronas**
**= 150.5 Millones de Parámetros**

**Nota:** Solo en la primera capa oculta.

Inviable computacionalmente / Sobreajuste severo garantizado.

## Pérdida de Geometría Espacial



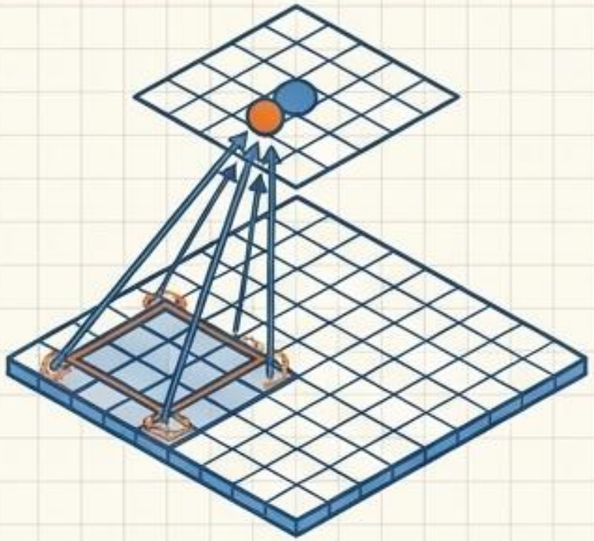

Aplanar la imagen a 1D destruye la vecindad. Un objeto desplazado espacialmente genera un vector numéricamente irreconocible.

**Conclusión técnica:** Carencia de invarianza a la traslación y pérdida total de estructura espacial local.

# La Operación de Convolución: Fundamento Matemático

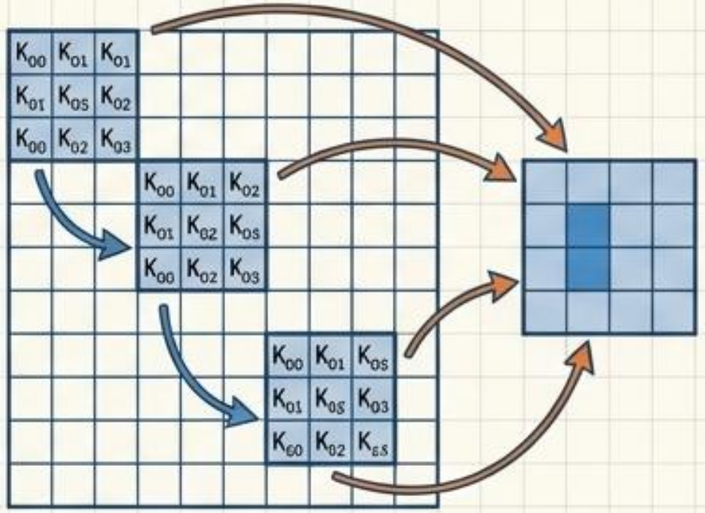
$$(I * K)[i,j] = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} I[i+m, j+n] \cdot K[m,n]$$

## Conectividad Local



El campo receptivo restringe las conexiones. En lugar de conectar todos los píxeles, se procesan vecindades locales, reduciendo parámetros drásticamente.

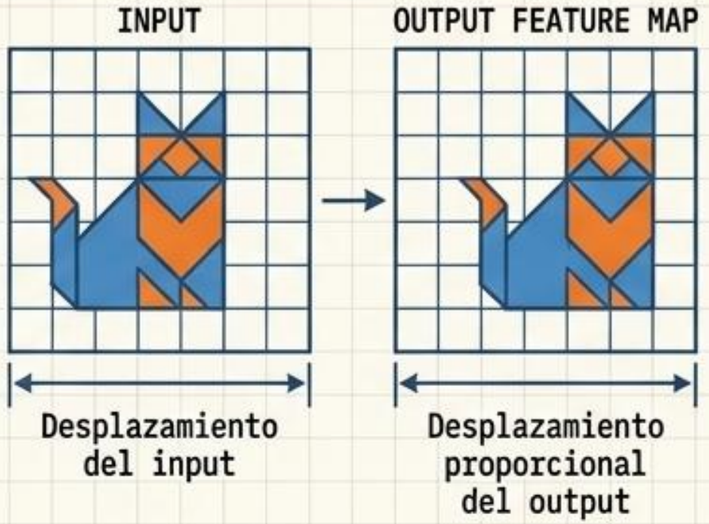
## Compartición de Pesos



El mismo filtro mapea toda la entrada.

Un patrón aprendido en la coordenada [x,y] se detecta automáticamente en cualquier otra región de la imagen.

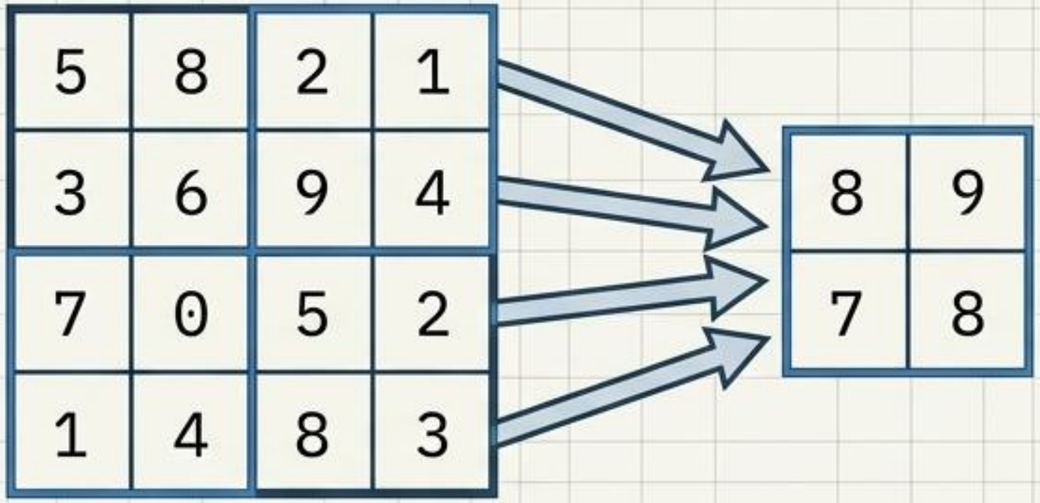
## Equivarianza a Traslación




Desplazamiento del input = Desplazamiento proporcional del output.

La detección de features es independiente de su posición absoluta.

# Pooling y Control de Dimensionalidad




## Calculadora de Salida Espacial

$$W_{out} = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$

W = Entrada, K = Tamaño de Kernel, P = Padding, S = Stride

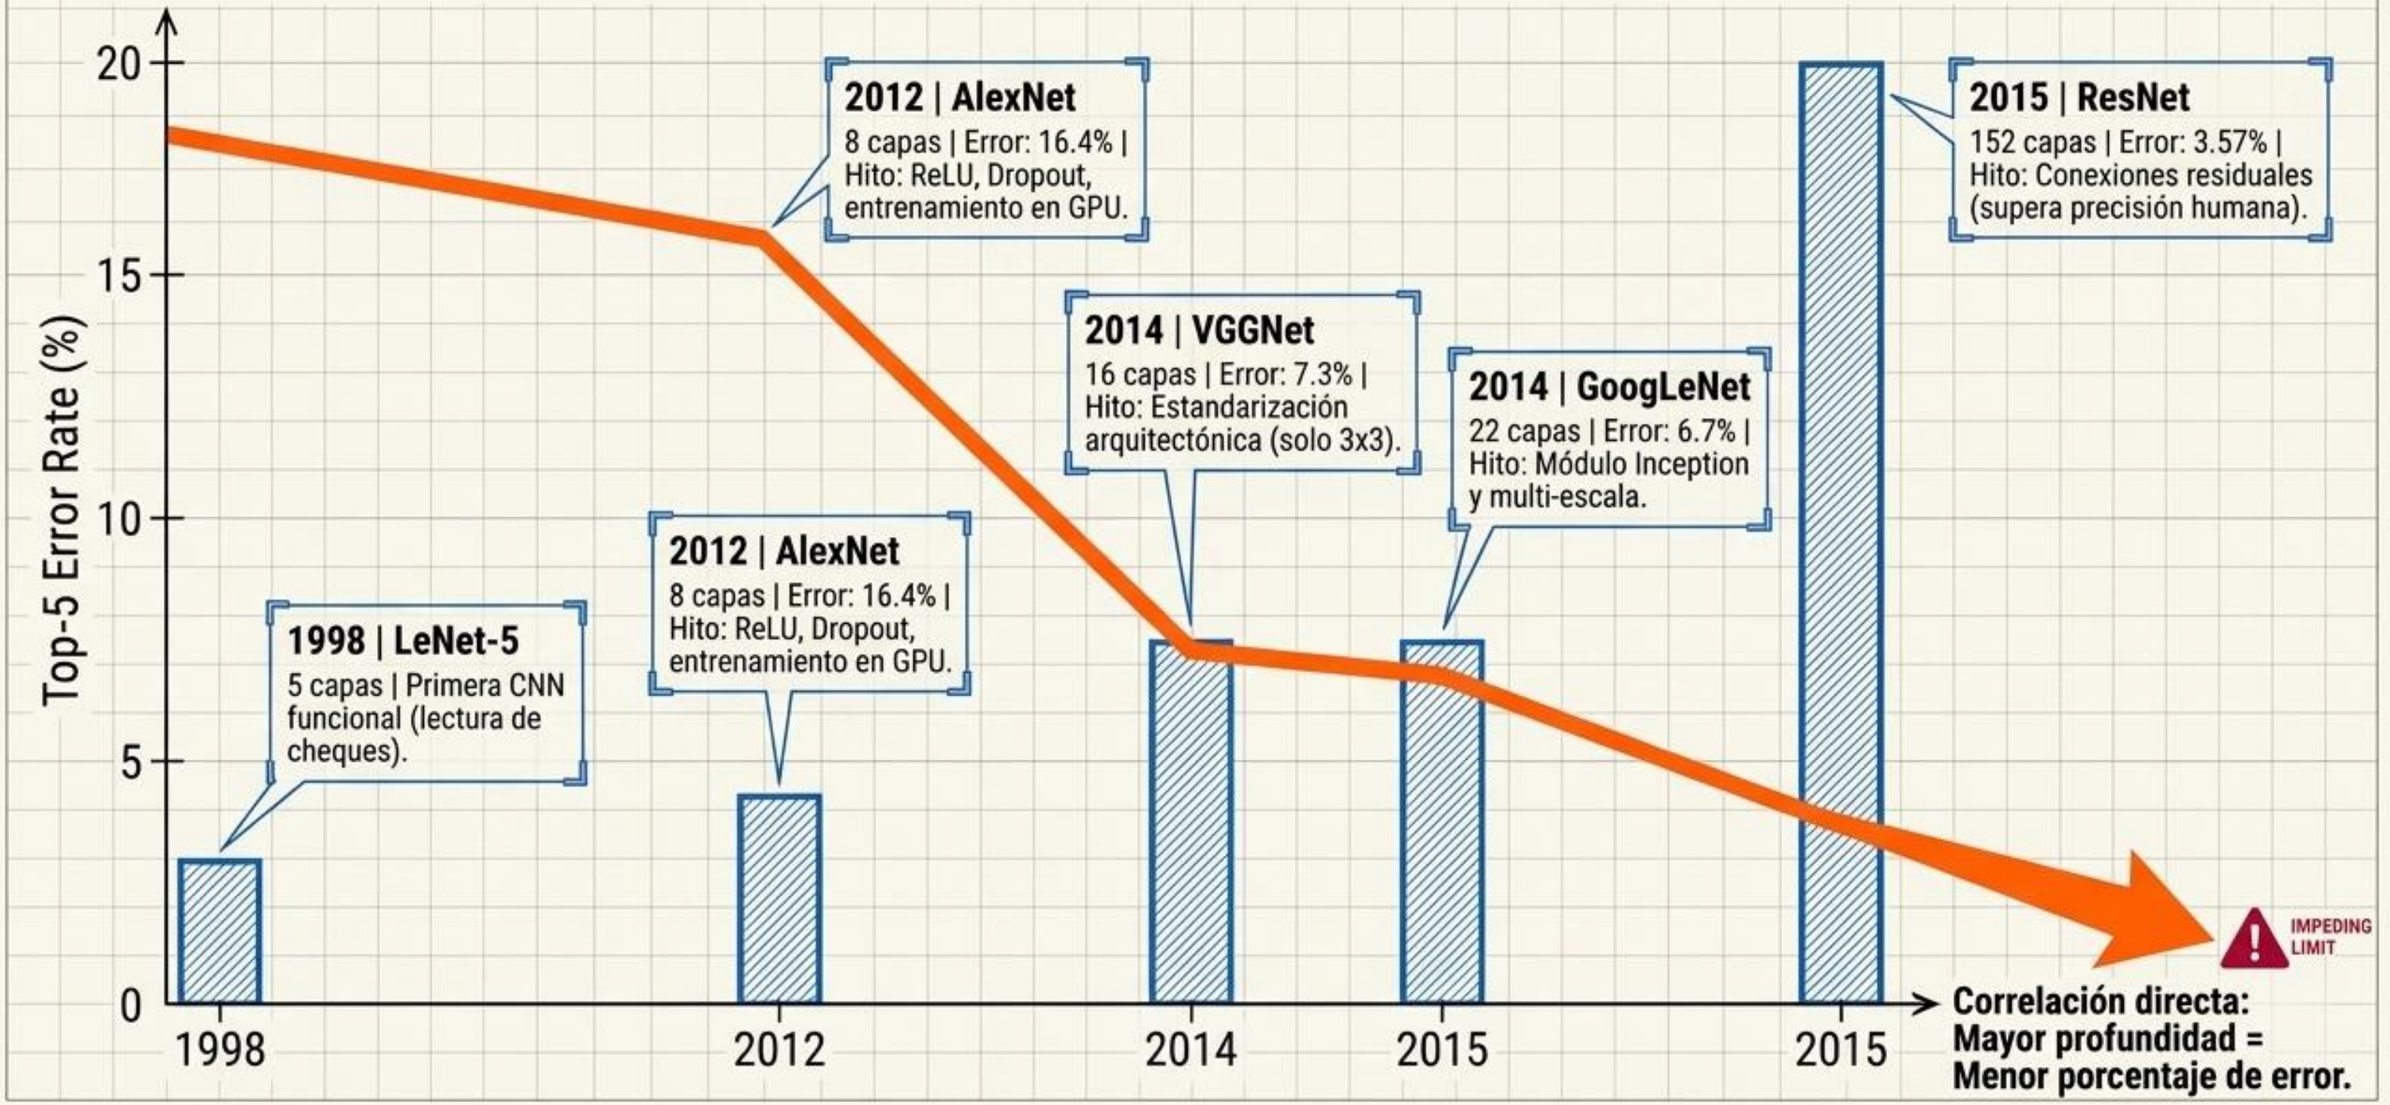
**Ejemplo de Reducción con Stride 2:**

Entrada 32×32 con S=2 → Reducción exacta a 16×16.

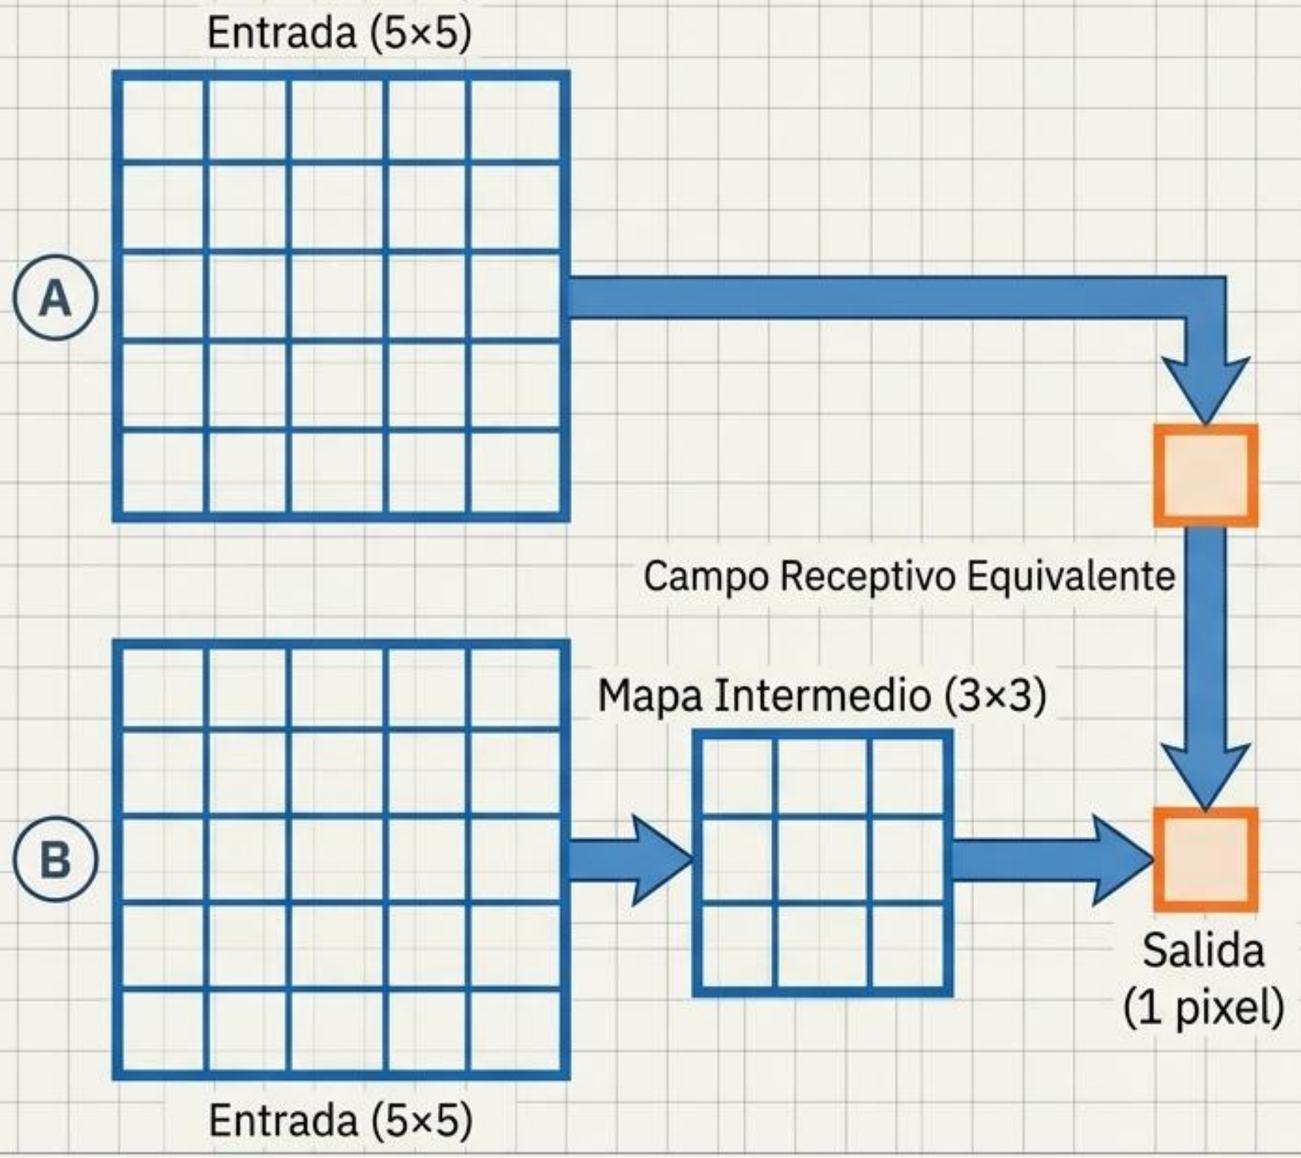
## Estrategias de Pooling

| | |
|---|---|
| Max Pooling | Toma el valor máximo de la ventana local. Preserva activaciones fuertes y bordes. Es el estándar de la industria (ej. 2x2, stride 2). |
| Average Pooling | Calcula el promedio matemático de la ventana. Suaviza la extracción de características. |
| Global Average Pooling (GAP) | Promedia la totalidad del mapa de características a un único escalar numérico. Reemplaza las densas capas Fully Connected finales. |

# La Carrera Armamentista de ILSVRC (2012-2015)



# VGGNet y el Principio del Campo Receptivo Equivalente



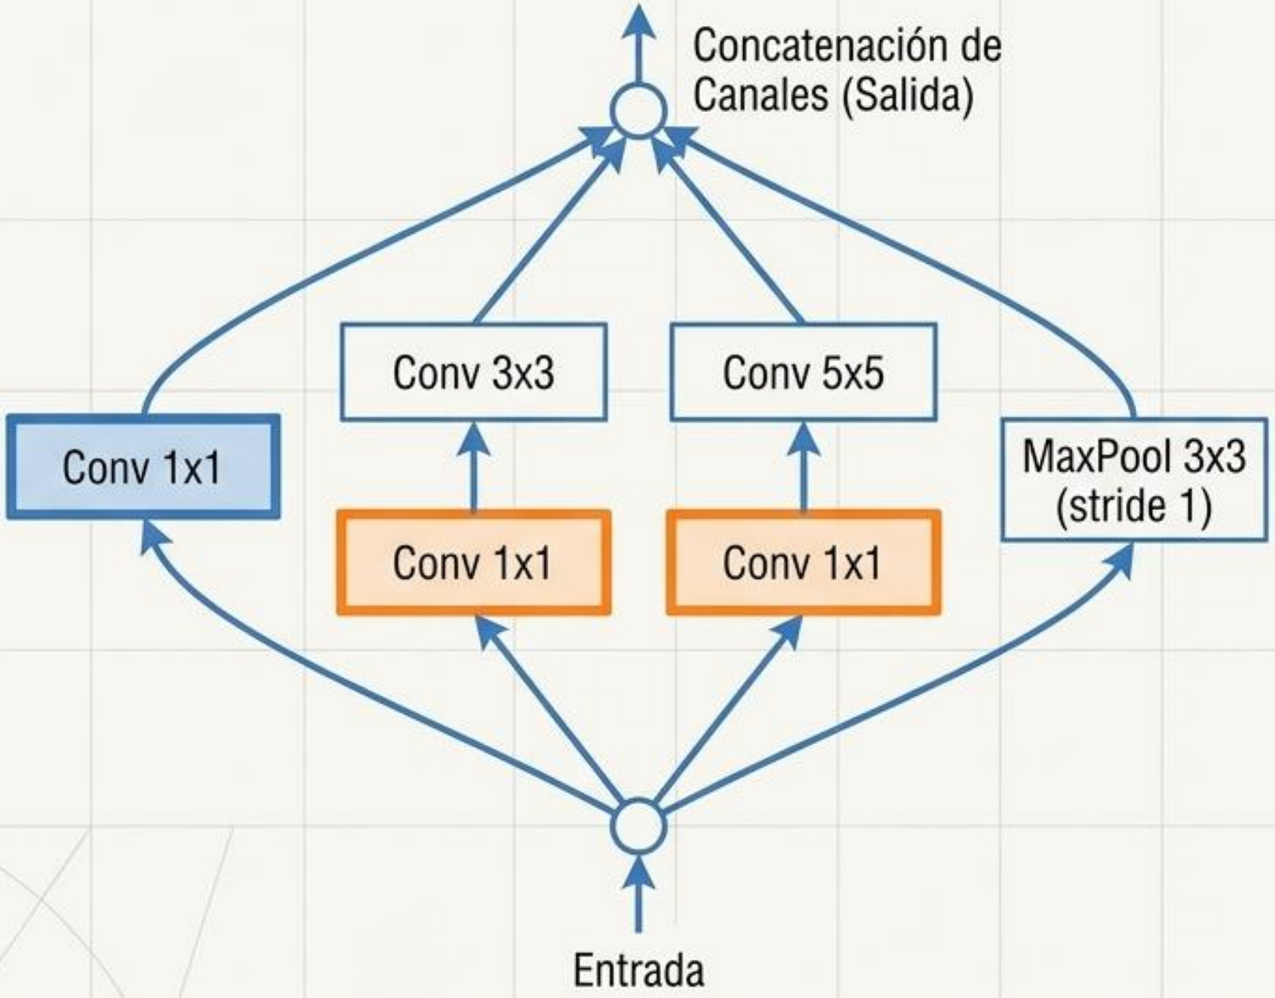

## Prueba Geométrica:

- 1 capa de 5×5 = **25 parámetros.** (1 Función de Activación).
- 2 capas de 3×3 = **18 parámetros** (28% menos). (2 Funciones de Activación, mayor no-linealidad).

## Arquitectura VGG-16

- **Patrón estricto:** Bloques sucesivos de Conv(3x3) → Conv(3x3) → Pool.
- **Costo Computacional:** ~138 millones de parámetros totales.
- **Diagnóstico:** Excelente extractor de características, pero prohibitivamente pesado debido a sus capas densas (Fully Connected) finales.

# GoogLeNet y la Magia de la Reducción 1×1




## El Bottleneck 1×1 (Demostración Matemática)

**Objetivo:** Aplicar filtro 5x5 sobre 256 canales.

Sin reducción:

$256 \times 256 \times 5 \times 5 =$ **1,638,400** operaciones.

Con Conv 1x1 (Reducción 256→64):

$(256 \times 64) + (64 \times 256 \times 5 \times 5) =$ **425,984** operaciones.

**Veredicto: 74% menos cómputo.**

Las convoluciones 1x1 actúan como una reducción de dimensionalidad crítica en el eje de canales.

# El Muro: El Problema de la Degradación




## Análisis Técnico del Fallo

**Paradoja Matemática:**

Una red de 56 capas debería, como mínimo, igualar la precisión de una de 20 capas si las 36 capas adicionales simplemente aprenden la función identidad.

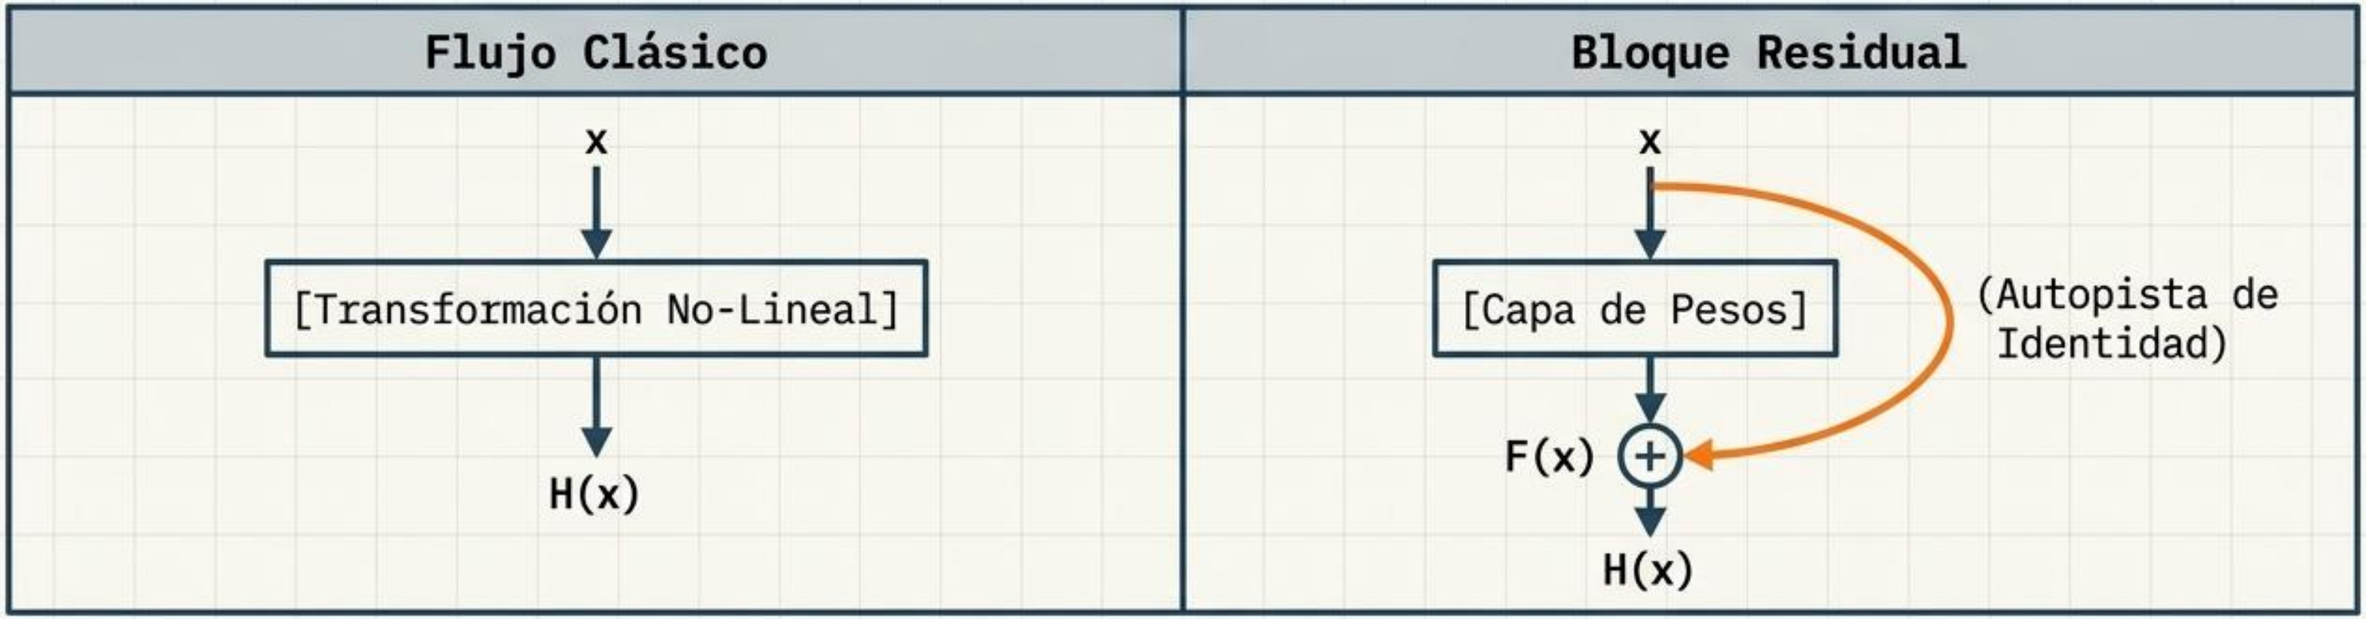
**Fallo del Optimizador:**

El gradiente estocástico (SGD) no logra encontrar la solución identidad óptima debido a las distorsiones introducidas por las activaciones no lineales (ReLU).

**Flujo Roto:**

Los landscapes de optimización extremadamente complejos, los gradientes desvanecientes (vanishing gradients) y los puntos de silla ahogan la señal de aprendizaje.

# ResNet: La Hipótesis Residual y la Conexión "Skip"




x → [Capa de Pesos] → F(x) + x ← (Autopista de Identidad)

**Formulación Matemática:**

En lugar de forzar a la red a aprender **H(x)** directamente de forma aislada, forzamos a la red a aprender únicamente el residuo:

$$F(x) = H(x) - x$$

Produciendo la salida final:

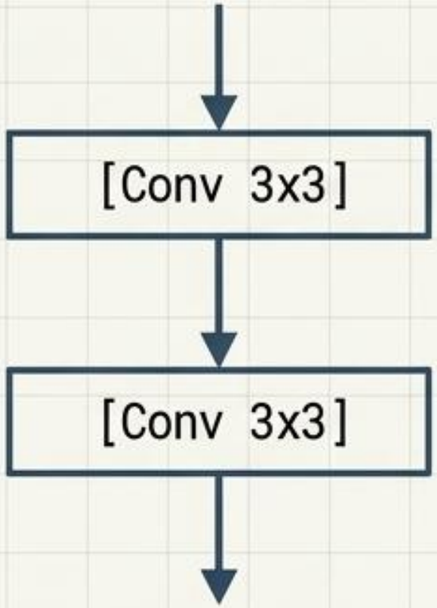
$$H(x) = F(x) + x$$

**El Secreto del Gradiente:**

La derivada de **(F(x) + x)** es **F'(x) + 1**. El término constante **'+ 1'** actúa como un **salvavidas matemático**, garantizando que la **señal del gradiente jamás desaparezca**, lo que permite entrenar redes con profundidad teóricamente infinita.

# Escalabilidad: Bloque Básico vs. Cuello de Botella

## Bloque Básico (ResNet-18/34)



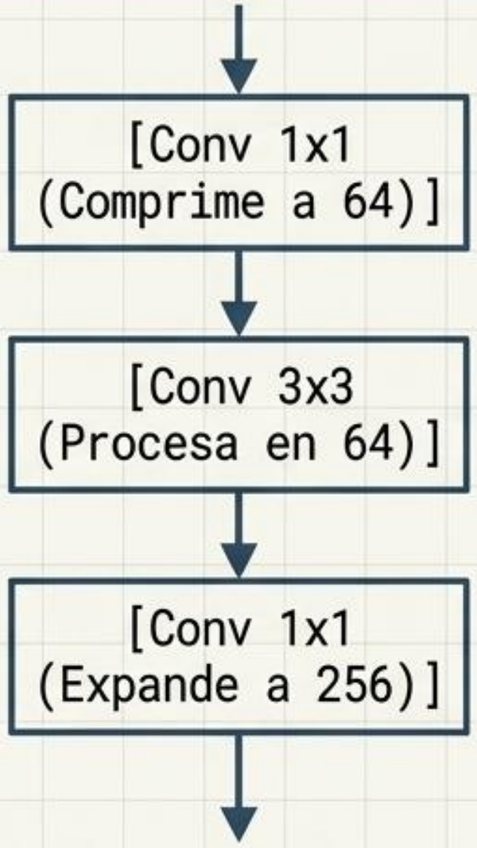

Entran 256 canales, se procesan íntegramente en 256 canales.

## Tabla de Costo Computacional (para 256 canales)

| | |
|---|---|
| Basic Block: | **~1,179,648** operaciones (**~1.18M** parámetros) |
| Bottleneck: | **~69,632** operaciones (**~70K** parámetros) |

**⚠ Attention:**
El **bloque de cuello de botella** es **~17× más eficiente en parámetros**, lo que habilita la escalabilidad hacia redes **ultra-profundas** (ej. ResNet-152) sin colapso de memoria.

## Bloque Bottleneck (ResNet-50/101/152)



# Batch Normalization: El Habilitador Estructural

## Internal Covariate Shift

Estandariza las activaciones en cada mini-batch:

$$\mu_B \text{ (media)}, \ \sigma_B^2 \text{ (varianza)}$$

Fórmula de Normalización:

$$\hat{x} = \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

Recuperación de capacidad representacional:

$$y = \gamma \cdot \hat{x} + \beta$$

($\gamma$ y $\beta$ son parámetros aprendibles por la red)

## Topología de Posicionamiento

Original (2015)

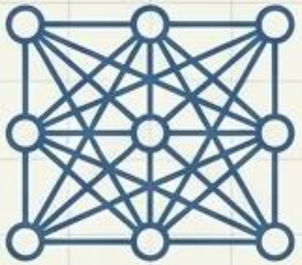
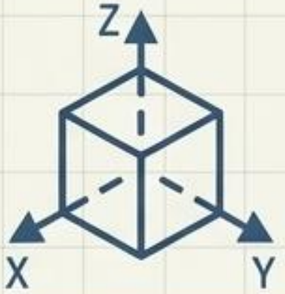



Pre-activation (2016)




**⚠ Nota de Ingeniería:**
La arquitectura Pre-activation mantiene el 'skip connection' como una vía de identidad completamente pura, mejorando significativamente el flujo en redes de más de 100 capas.

# Más allá de ResNet: Vectores de Evolución (2017-2019)

| ResNeXt (Cardinalidad) | DenseNet (Reutilización) | EfficientNet (Escalamiento) |
|---|---|---|
|  |  |  |
| **Mecanismo**<br>Introduce el concepto de cardinalidad. Múltiples caminos paralelos (ej. 32 transformaciones simples) en lugar de una compleja. | **Mecanismo**<br>Conexión total. Cada capa recibe inputs directos de TODAS las capas previas en el bloque. | **Mecanismo**<br>Compound Scaling. Escala matemáticamente Profundidad, Ancho y Resolución en simultáneo ($\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$). |
| **Logro**<br>Supera a ResNet estándar manteniendo el mismo presupuesto computacional exacto. | **Logro**<br>Máxima eficiencia del flujo de gradientes, requiere muchos menos parámetros (low growth rate). | **Logro**<br>EfficientNet-B3 (12M parámetros) supera en precisión a ResNet-152 (60M parámetros) siendo 5× más eficiente. |

# Implementación Práctica: Transfer Learning vs. Fine-Tuning

## Transfer Learning (Extractor Fijo)

```
base = ResNet50(weights='imagenet',
                include_top=False)

base_model.trainable = False

head = GlobalAveragePooling2D()
out = Dense(num_classes)(head)
```

**Nota:** La red base se mantiene congelada. Se entrena solo la nueva cabeza usando un Learning Rate estándar (ej. 1e-3).

## Fine-Tuning (Ajuste Fino Acoplado)

```
base_model.trainable = True

for layer in base_model.layers[:-20]:
    layer.trainable = False

optimizer=Adam(learning_rate=1e-5)
```

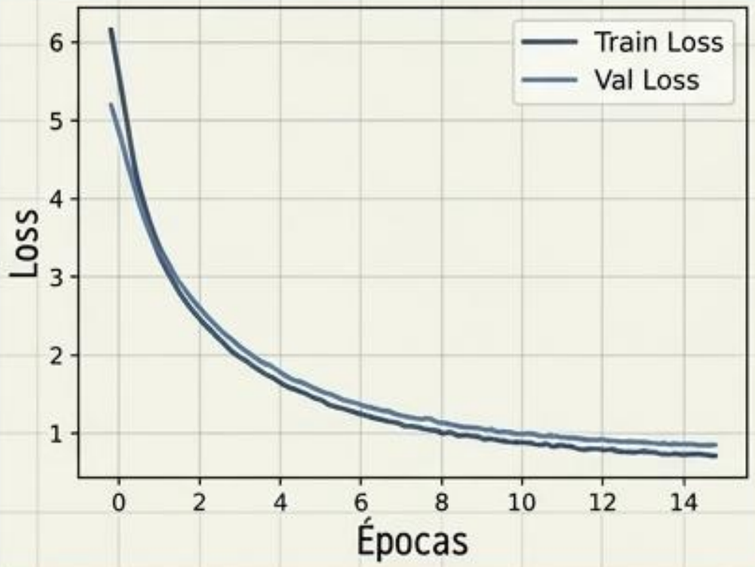


⚠ **Regla de Oro:** Recompilar obligatoriamente con un Learning Rate 10x-100x menor para evitar destruir los pesos pre-entrenados de las capas profundas.

# Diagnóstico Visual: Interpretación de Curvas de Aprendizaje

## Diagnostics Dashboard

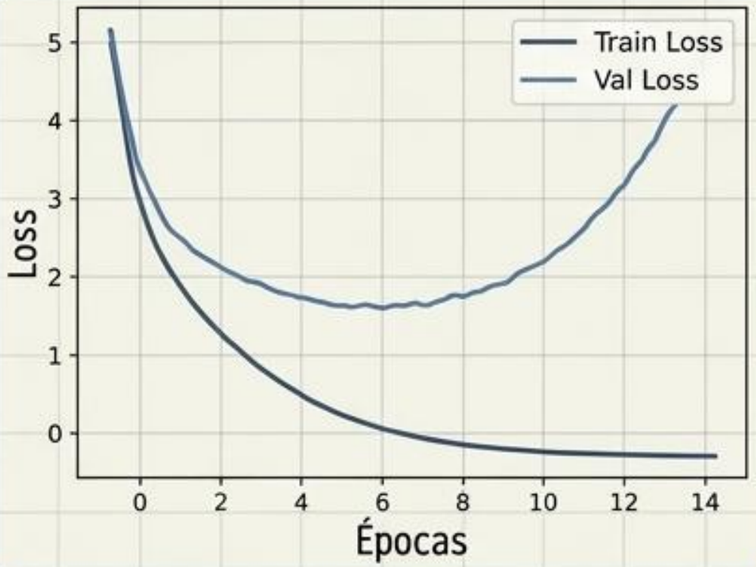
### Ajuste Óptimo




Estado óptimo y saludable.

**Acción:** Guardar pesos finales (ModelCheckpoint).

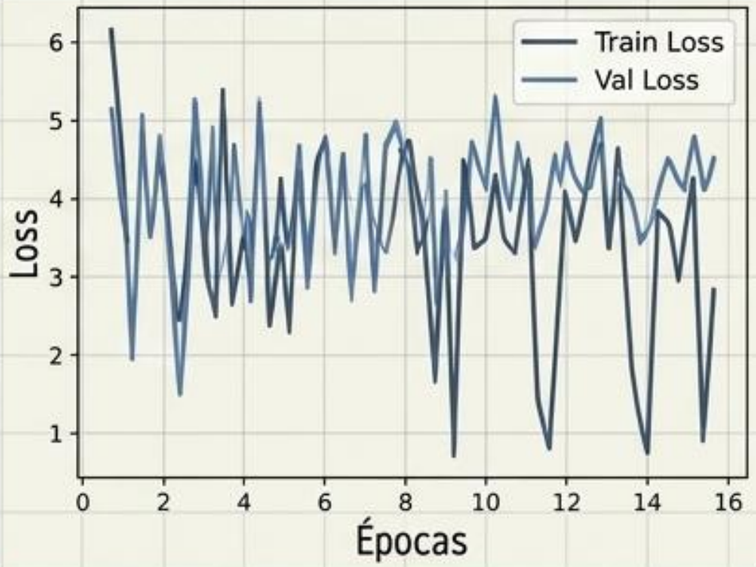
### Overfitting (Sobreajuste)




**Diagnóstico:** La red memoriza el set; no generaliza.

**Acción:** Aumentar Data Augmentation, añadir capas de Dropout, o aplicar EarlyStopping de inmediato.

### Underfitting / Learning Rate Excesivo




**Diagnóstico:** El optimizador salta violentamente el mínimo global o falta capacidad.

**Acción:** Implementar Scheduler de LR (Cosine Decay) o reducir la tasa base.

# Datasets de Prototipado y Referencias Fundamentales

| Tabla de Datasets (Clasificados por Nivel) | |
|---|---|
| **Nivel/Dataset** | **Descripción y Características** |
| Nivel Introductorio: Fashion-MNIST | 28x28, 10 clases. Sustituto moderno y complejo del MNIST original. |
| Nivel Intermedio: CIFAR-10 | 32x32x3, 60K imágenes. Dataset ideal para prototipar arquitecturas ResNet desde cero. |
| Nivel Avanzado: ImageNet (ILSVRC) | 1.2M imágenes, 1000 clases. El benchmark y estándar industrial definitivo. |

## Bibliografía Académica Clave


- He, K. et al. (2015). Deep Residual Learning for Image Recognition. CVPR. (Paper original ResNet).
- Simonyan, K. & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. (Paper VGG).
- Goodfellow, I. et al. (2016). Deep Learning. MIT Press.
- Recursos Adicionales: tf.keras.applications y curso Stanford CS231n.