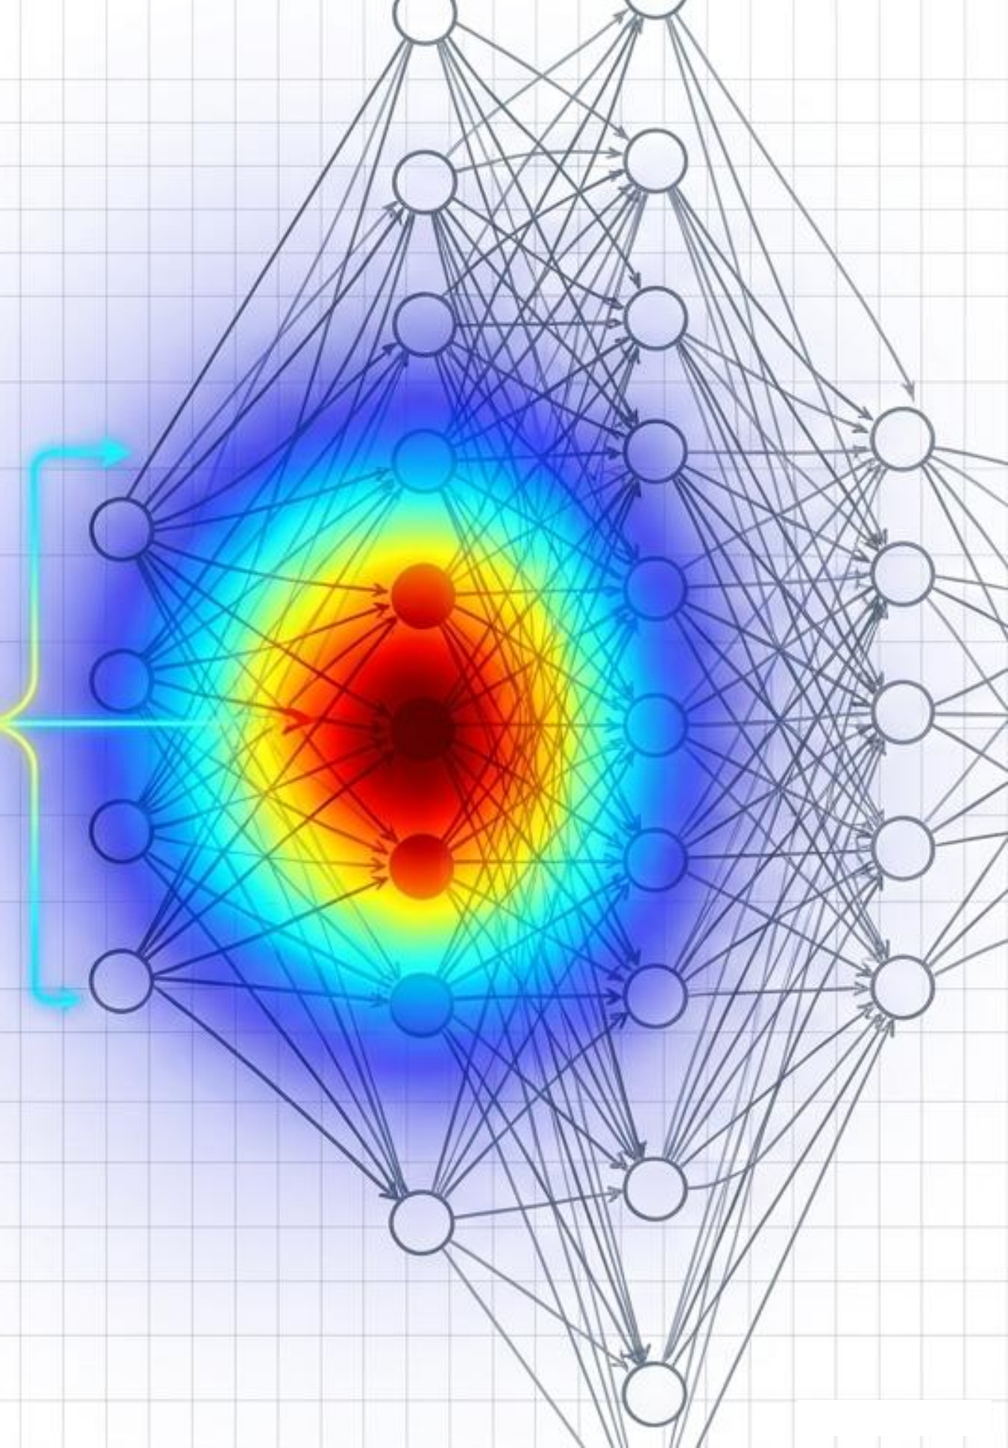
Sesión 07 (Parte B): Interpretabilidad y Explicabilidad en Deep Learning

¿Por qué el modelo decide lo que decide?



CASE 1

Nivel:
Intermedio → Avanzado

CASE 3

Univer:
Univisidad Nacional del Centro del Perú — UNCP

CASE 2

Curso:
Ingeniería del Conocimiento (ISO56B)

CASE 4

Docente:
Msc. Jaime Antonio Huaytalla Pariona

El Dilema de la Caja Negra: No Basta con Acertar



El Médico

El modelo predice neumonía con excelente **F1-Score**, pero la pregunta crítica es: ¿POR QUÉ? ¿Está mirando el tejido pulmonar o simplemente una **marca de agua del hospital** en la esquina?



El Juez

Un juez que dicta **'culpable'** sin presentar ninguna justificación es **inaceptable**. En la IA crítica, una predicción correcta sin explicación carece de **validez ética y práctica**.

El Caso del Atajo: Cuando el Modelo ‘Hace Trampa’

La Evidencia



Predicción: **Husky**



Predicción: **Lobo**

El modelo aprendió un “**shortcut**” (atajo).
Nieve = Lobo. Pasto = Husky.
Nunca aprendió a ver al animal.

5 Razones para Interpretar

Confianza	Depuración	Sesgo	Regulación	Mejora
El usuario final necesita verificar la decisión.	Detectar atajos ("shortcuts") en lugar de features reales.	Evitar discriminación por características irrelevantes.	Cumplir con leyes de "derecho a explicación" (GDPR).	Entender debilidades para mejorar la arquit

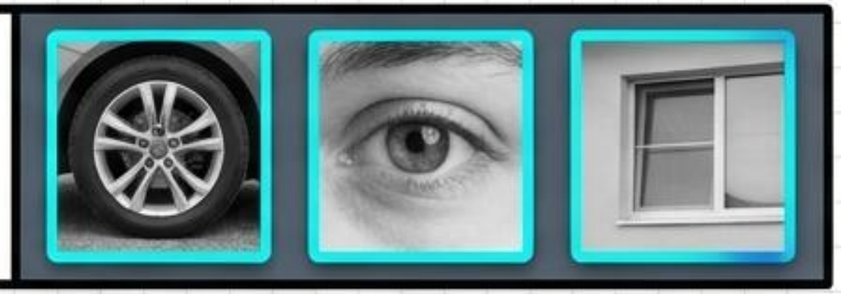
Nota: *Para redes complejas, usamos técnicas Post-hoc (aplicadas después del entrenamiento).*

Rastreando las Pistas: ¿Qué Aprende Cada Capa?

Nivel 3: Capas Conv4+ (El Investigador Principal)
Llega a la conclusión uniendo los patrones
para identificar conceptos completos.



Nivel 2: Capas Conv2-3 (El Analista de Patrones)
Combina pistas básicas para formar partes reconocibles.



Nivel 1: Capa Conv1 (El Detective de Campo)
Busca pistas muy básicas: bordes, líneas, gradientes de color.



Extracción de Evidencia: Visualizando Feature Maps

El Procedimiento

```
filtros, biases =
model.layers[0].get_weights()

capas_conv = [L.output for L in
  model.layers if 'conv' in
  L.name]

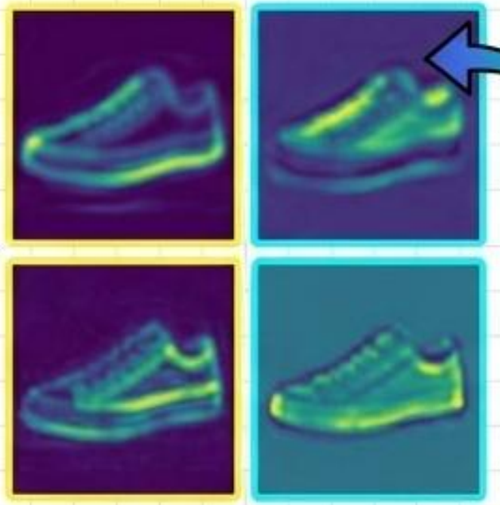
modelo_activaciones =
  tf.keras.Model
  (inputs=model.input,
  outputs=capas_conv)

activaciones =
modelo_activaciones.predict
(img_input)
```

Los Resultados



Zapatilla



Activa fuertemente filtros de **contornos curvos**.



Bolsa



Activa detectores de **bordes rectos** (horizontales y **verticales**).

Grad-CAM: El Examen con Resaltador

Analogía:
Pides a un estudiante resolver un examen y usar un **resaltador** amarillo para marcar la parte exacta del enunciado que le dio la respuesta.

[1] Elegir

Clase objetivo (ej. 'Zapatilla').

[2] Calcular

Gradientes respecto a mapas de la última capa.

[3] Promediar

Gradientes para medir la importancia.

[4] Combinar

Mapas de características ponderados.

[5] Filtrar

Aplicar ReLU (solo contribuciones positivas).

[6] Escalar

Redimensionar al tamaño original.

Implementación de Grad-CAM Paso a Paso

Aquí **rastreamos cómo cambian las activaciones frente a la clase objetivo**.

```
with tf.GradientTape() as tape:
    conv_output, predicciones = grad_model(img_tensor)
    clase_output = predicciones[:, indice_clase]

  gradientes = tape.gradient(clase_output, conv_output)
  pesos = tf.reduce_mean(gradientes, axis=(0, 1, 2))
  heatmap = tf.reduce_sum(conv_output[0] * pesos, axis=-1)

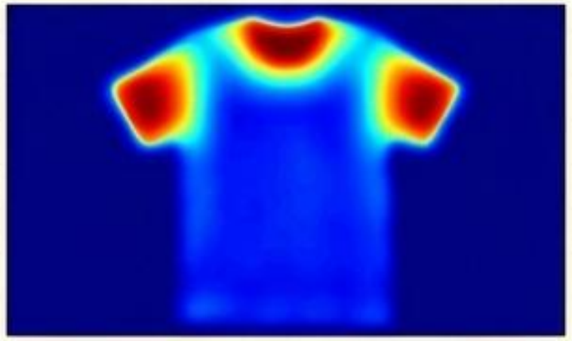
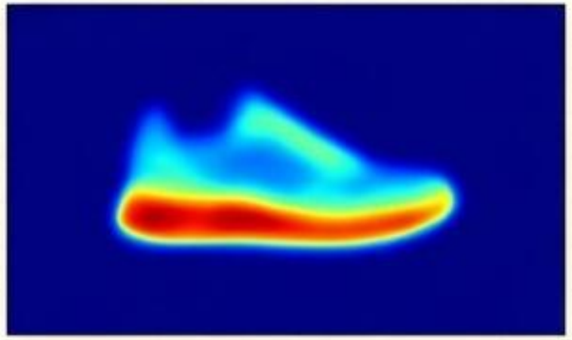
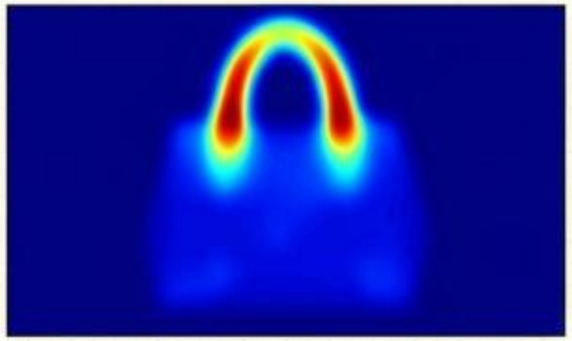
  heatmap = tf.nn.relu(heatmap)

  heatmap_colored = cm.jet(heatmap_resized)[:, :, :3]
```

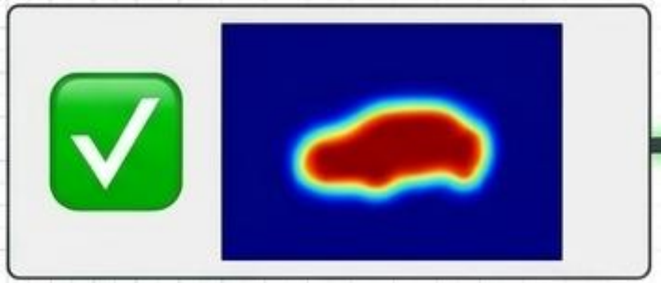
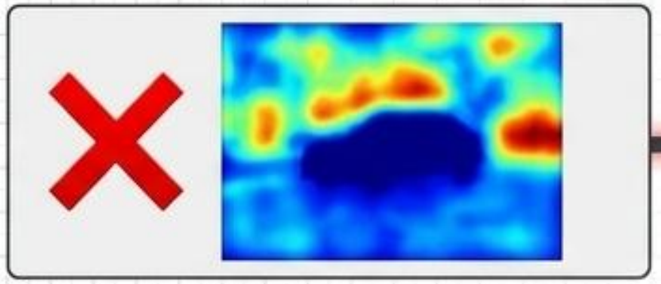
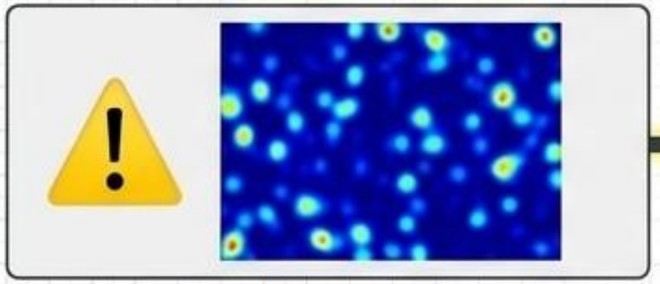
Fundamental: ignoramos los píxeles que restan probabilidad, solo queremos los que **suman**.

Aplicamos **mapa 'jet'** para **termografía visual** (**Rojo = Caliente/Importante**).

El Modelo en Acción: Evidencia Multiclase

Imagen Original	Mapa de Calor (Jet)	Superposición
		
		
		

Diagnóstico Forense: Interpretando Patrones de Calor

	Significado	Acción
	Concentrado en Objeto. Buena generalización. Aprende features correctas.	Listo para validación y producción.
	Concentrado en el Fondo. Atajo (Shortcut). El modelo no mira el objeto.	Ampliar variedad del dataset (Data Augmentation) o aislar imágenes.
	Disperso sin Patrón. Subentrenamiento. El modelo no tiene estrategia clara.	Ajustar hiperparámetros, entrenar por más épocas.
	Concentrado en Marca Irrelevante. Sesgo en los datos.	Limpiar/enmascarar artefactos en las imágenes originales.

Tiro por la Culata: Analizando Errores del Modelo

ERROR



Clase Real: **Bota**



Clase Predicha: Zapatilla

Anotación del Detective: Insight

Anotación del Detective: ¿Por qué falló el modelo? El campo de atención fue demasiado estrecho. El modelo se concentró **únicamente** en la suela plana inferior (idéntica a la de una zapatilla) e **ignoró completamente la caña alta geométrica que define a una bota. Grad-CAM revela la fuente exacta de la confusión.**

LIME: Explicaciones Locales por Perturbación

El Concepto

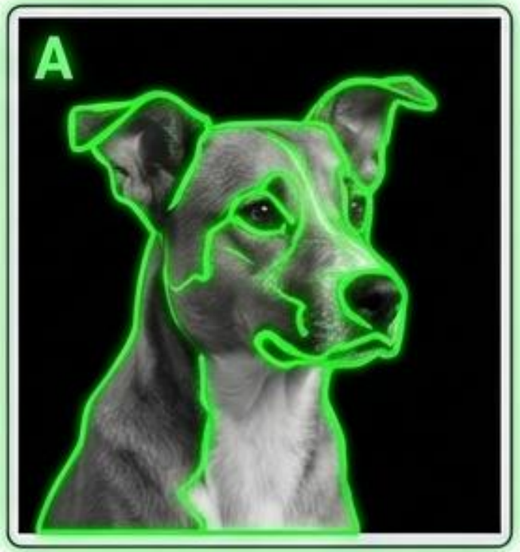
El Detective que Tapa Pistas



LIME divide la imagen en "superpíxeles". Tapa diferentes partes y pregunta: "¿Aún puedes reconocer la clase?". Si la respuesta cambia drásticamente, esa parte era vital.

Implementación y Visualización

```
explicador = lime_image.LimeImageExplainer()
explicacion = explicador.explain_instance(imagen,
predict_fn, num_samples=1000)
```



Bordes Verdes = A favor de la predicción



Bordes Rojos = En contra

SHAP: El Peso de la Evidencia (Valores de Shapley)

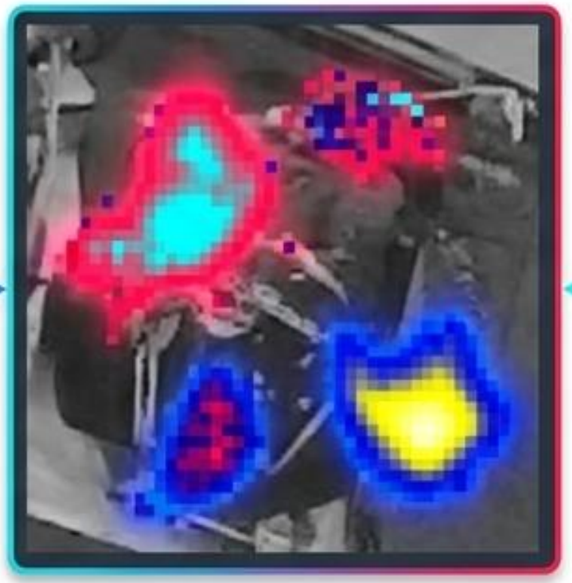
Teoría de Juegos: El Equipo



Si un equipo gana, ¿cuánto contribuyó exactamente cada jugador? **SHAP** prueba **combinaciones matemáticas** de píxeles para hallar el **'valor justo'** e **impacto** de cada uno en la predicción.

Implementación y Visualización

```
explainer = shap.DeepExplainer(model, background)
shap_values = explainer.shap_values(imagenes_explicar)
shap.image_plot(shap_values, imagenes_explicar)
```



Color Rojo = Contribución positiva (aumenta probabilidad)
Color Azul = Contribución negativa (disminuye probabilidad)
Intensidad = Magnitud del impacto

El Veredicto Final: ¿Qué Método Elijo?

MÉTODO	VELOCIDAD	FIDELIDAD / AGNÓSTICO	CASO DE USO IDEAL
Feature Maps	**Rápido**	**Fidelidad Alta**	Ideal para ver qué patrones específicos se activan en la red.
Grad-CAM	**Rápido**	**Fidelidad Alta**	El estándar para CNNs. Altamente visual, ideal para localizar regiones clave.
LIME	**Lento**	**Agnóstico**	Útil para perturbación visual directa en cualquier tipo de modelo.
SHAP	**Lento**	**Agnóstico**	Cuando se requiere rigor matemático absoluto y garantías teóricas.

Recomendación Oficial - Estándar ISO56B

Regla de Oro del Curso:

- **Utiliza Grad-CAM siempre como herramienta principal para proyectos de visión artificial.**
- **Usa Feature Maps para validación estructural.**
- **Reserva LIME/SHAP como bonus para arquitecturas complejas o no-CNN.**

El Pipeline Completo y Próximos Pasos

Bloque 1: Evaluación (Parte A)

F1-Score, Matriz de Confusión

➔ Nos dice **QUÉ TAN BIEN** funciona el modelo.

+

Bloque 2: Interpretabilidad (Parte B)

Grad-CAM, Feature Maps

➔ Nos dice **POR QUÉ** toma esas decisiones.



Sesión 8: Proyecto CNN End-to-End

Integración Total: Arquitectura + Optimización + Evaluación + Explicabilidad en un solo flujo de trabajo trabajo profesional.