UNIVERSIDAD NACIONAL DEL CENTRO DEL PERÚ

FACULTAD DE INGENIERÍA DE SISTEMAS

INGENIERÍA DEL CONOCIMIENTO

Evaluación Parcial (2025-II)

INDICACIONES:

- Formar grupos de hasta 4 integrantes.

- La presentación de una misma solución por dos o más grupos, generará la desaprobación automática de los grupos involucrados.

---

1. ACTIVIDAD: Pipeline de Machine Learning Clásico sobre Dataset Real

1.1. CONSIGNA

Contexto: Cada grupo elegirá libremente un dataset tabular de clasificación de una fuente pública reconocida (ver Sección 1.2 — Repositorios recomendados). Ningún grupo podrá usar el mismo dataset. *El dataset no debe haber sido utilizado en ninguna sesión del curso.*

El notebook debe contener las siguientes secciones, en este orden:

SECCIÓN A — Presentación (celda markdown)

1. Nombre del curso, semestre y fecha
2. Nombres y códigos de los 4 integrantes
3. Nombre del dataset elegido, fuente (URL) y justificación de la elección
4. Descripción del problema en 3–5 líneas

SECCIÓN B — Carga y Análisis Exploratorio de Datos (EDA)

1. Cargar el dataset desde URL pública o archivo incluido en el Colab
2. Mostrar las primeras filas, shape, tipos de datos y valores nulos
3. Distribución de la variable objetivo (gráfico de barras con conteo y porcentaje)
4. Estadísticas descriptivas de las variables numéricas
5. Al menos 2 visualizaciones adicionales relevantes al dataset (histogramas, boxplots, correlación, pairplot u otras)
6. Conclusiones del EDA: párrafo de 5–8 líneas analizando hallazgos y decidiendo qué preprocesamiento aplicar

SECCIÓN C — Preprocesamiento

1. Tratamiento de valores nulos (justificar la estrategia: eliminar, imputar, etc.)

2. Codificación de variables categóricas si las hay (LabelEncoder, OneHotEncoder, get_dummies)
3. Escalado de variables numéricas (StandardScaler o MinMaxScaler — justificar elección)
4. Split train/test con estratificación (test_size=0.2, random_state fijo)
5. Verificar distribución de clases en train y test

SECCIÓN D — Modelado (Mínimo 3 modelos)

1. Entrenar al menos 3 modelos distintos: LogisticRegression, DecisionTree, RandomForest, SVM, KNN o GradientBoosting
2. Para cada modelo: entrenar con train, predecir sobre test
3. Mostrar accuracy, precision, recall, F1-score (classification_report)
4. Matriz de confusión con visualización (heatmap) para cada modelo

SECCIÓN E — Evaluación Comparativa

1. Tabla resumen con métricas de todos los modelos (accuracy, F1 macro, AUC si aplica)
2. Gráfico de barras comparando el rendimiento de los modelos
3. Curvas ROC de al menos 2 modelos (superpuestas en un mismo gráfico)
4. Análisis escrito: párrafo de 5–10 líneas explicando cuál modelo es el mejor y por qué

SECCIÓN F — Modelo Final y Serialización

1. Seleccionar el mejor modelo y re-entrenar con hiperparámetros optimizados (GridSearchCV o RandomizedSearchCV, al menos 2 hiperparámetros)
2. Evaluar el modelo optimizado sobre test
3. Serializar el modelo final con joblib.dump()
4. Demostrar la carga del modelo serializado con joblib.load() y predecir sobre nuevos datos

SECCIÓN G — Conclusiones (celda markdown)

1. Resumen de resultados en 5–8 líneas
2. Lecciones aprendidas por el grupo
3. Limitaciones encontradas en el dataset o los modelos
4. Posibles mejoras futuras

1.2. REPOSITORIOS RECOMENDADOS — ACTIVIDAD 1

Cada grupo elige libremente un dataset tabular de clasificación de cualquier fuente pública confiable. A continuación, se listan repositorios recomendados:

Repositorio	URL	Descripción
UCI Machine Learning Repository	archive.ics.uci.edu	Repositorio clásico con cientos de datasets tabulares de referencia académica
Kaggle Datasets	kaggle.com/datasets	Comunidad con miles de datasets de diversas áreas; filtrar por 'Classification'
Google Dataset Search	datasetsearch.research.google.com	Buscador de datasets de Google; agrega resultados de múltiples fuentes
OpenML	openml.org	Plataforma de ML abierta con datasets curados y benchmarks
data.gov	data.gov	Portal de datos abiertos del gobierno de EE.UU.; datasets reales de salud, educación, economía
Papers With Code — Datasets	paperswithcode.com/datasets	Datasets asociados a publicaciones científicas; filtrar por tarea y modalidad
Datos Abiertos — Perú	datosabiertos.gob.pe	Portal de datos abiertos del gobierno peruano
Hugging Face Datasets	huggingface.co/datasets	Repositorio colaborativo con datasets para ML; filtrar por 'tabular-classification'

Requisitos mínimos del dataset:

(a) Tabular de clasificación.

(b) al menos 500 registros y 5 features

(c) al menos 2 clases

(d) datos reales (no sintéticos)

(e) no utilizado en clase ni en los laboratorios.

1.3. RÚBRICA DE EVALUACIÓN — ACTIVIDAD 1

Escala vigesimal (0–20). *Nota_Actividad1 = (Nota_Notebook × 0.70) + (Nota_Defensa × 0.30)*

1.3.1. Nota del Notebook (70%)

Criterio	Peso	Excelente (18–20)	Bueno (14–17)	Regular (11–13)	Deficiente (0–10)
EDA y preprocesamiento	20%	EDA completo con ≥4 visualizaciones, preprocesamiento justificado paso a paso	EDA con 2–3 visualizaciones, preprocesamiento correcto sin justificar todas las decisiones	EDA superficial (1 visualización), preprocesamiento incompleto	Sin EDA o con errores graves; no hay preprocesamiento
Modelado	25%	≥3 modelos correctamente implementados, hiperparámetros explorados, código limpio	3 modelos con parámetros por defecto	1–2 modelos, implementación con errores menores	No implementa modelos o no ejecutan
Evaluación comparativa	25%	Tabla + gráfico + curvas ROC + análisis escrito de trade-offs detallado	Tabla y gráfico comparativo + análisis breve	Solo métricas numéricas sin visualización ni análisis	Sin evaluación comparativa
Modelo final y serialización	15%	GridSearchCV con ≥2 hiperparámetros, modelo serializado, demo de carga y predicción	Modelo reentrenado y serializado, sin búsqueda de hiperparámetros	Modelo serializado, pero sin optimización	No serializa el modelo
Calidad del código	15%	Código limpio, comentado, ejecutable, markdown formateado, visualizaciones con títulos	Código ejecutable con comentarios parciales	Código con errores menores, sin comentarios	No ejecuta o está desordenado

1.3.2. Nota de la Defensa Oral (30%)

Criterio	Peso	Excelente (18–20)	Bueno (14–17)	Regular (11–13)	Deficiente (0–10)
Dominio técnico	50%	Todos los integrantes responden con precisión y profundidad	Respuestas correctas con dudas menores	Respuestas parciales o imprecisas	No demuestra comprensión
Claridad de exposición	30%	Presentación fluida, estructurada, lenguaje técnico apropiado	Presentación clara con algunas imprecisiones	Presentación desorganizada	No logra comunicar el trabajo
Respuesta a preguntas	20%	Responde con ejemplos y justificación	Responde correctamente la mayoría	Respuestas vagas o incompletas	No responde o responde incorrectamente

Nota individual: *Si en la defensa un integrante no demuestra participación real en el trabajo, el docente puede ajustar su nota individual hasta 5 puntos por debajo de la nota grupal.*

1.4. BANCO DE PREGUNTAS ORIENTATIVAS

i. ¿Por qué eligieron ese tipo de escalado y no otro? ¿Qué pasaría con SVM si no escalaran?
ii. ¿Cuál es la diferencia entre accuracy y F1-score? ¿Cuándo conviene más uno que otro?
iii. ¿Qué significa un recall bajo en la clase minoritaria? ¿Cómo lo mejorarían?
iv. Expliquen qué hiperparámetros ajustaron en GridSearchCV y por qué eligieron esos.
v. ¿Qué ventajas tiene serializar el modelo con joblib? ¿En qué escenario real lo usarían?
vi. Si tuvieran más datos, ¿cambiarían de modelo? ¿Por qué?
vii. ¿Qué pasaría si no estratificaran el split train/test?
viii. ¿Cómo interpretaron la curva ROC de su mejor modelo?
ix. ¿Qué limitaciones encontraron en su dataset? ¿Cómo las mitigaron?
x. ¿Qué harían distinto si pudieran repetir el proyecto?

2. ACTIVIDAD: Red Neuronal Convolucional sobre Dataset de Imagen Real

2.1. CONSIGNA

Contexto: Cada grupo elegirá libremente un dataset de clasificación de imágenes de una fuente pública reconocida (ver Sección 2.2 — Repositorios recomendados). Ningún grupo podrá usar el mismo dataset. *El dataset no debe haber sido utilizado en ninguna sesión del curso.*

Importante: El notebook debe ejecutarse con GPU habilitada (Runtime → Change runtime type → T4 GPU).

El notebook debe contener las siguientes secciones, en este orden:

SECCIÓN A — Presentación (celda markdown)

1. Nombre del curso, semestre y fecha
2. Nombres y códigos de los 4 integrantes
3. Nombre del dataset elegido, fuente (URL) y justificación de la elección
4. Descripción del problema de clasificación en 3–5 líneas
5. Indicación de que se usó GPU (Runtime → Change runtime type → T4 GPU)

SECCIÓN B — Carga, Exploración y Preprocesamiento

1. Cargar el dataset (vía tf.keras.datasets o descarga directa)
2. Mostrar dimensiones: número de imágenes (train/test), resolución, canales
3. Grilla de ejemplos: mostrar al menos 1 imagen de cada clase con su etiqueta (plt.subplots)
4. Distribución de clases (gráfico de barras)
5. Normalizar los píxeles a [0, 1] y reshape si es necesario
6. Separar un conjunto de validación (10% del train, con estratificación)
7. Resumen numérico: total train, val, test, shape final

SECCIÓN C — CNN Base (sin regularización)

1. Diseñar CNN base: al menos 2 bloques convolucionales (Conv2D + MaxPooling2D) + Flatten + Dense(s) + softmax
2. Compilar con Adam y sparse_categorical_crossentropy
3. Mostrar model.summary() y contar parámetros
4. Entrenar por 15–20 épocas

5. Graficar curvas de accuracy y loss (train vs val)
6. Diagnóstico de overfitting: explicar en un párrafo observando la brecha train-val

SECCIÓN D — CNN Mejorada (con regularización)

1. Incluir al menos 3 técnicas: Data Augmentation (visualizar 4 variaciones), Batch Normalization, Dropout, GAP, L2 regularization
2. Entrenar con callbacks: EarlyStopping (patience ≥ 5, restore_best_weights=True) y ReduceLROnPlateau (factor=0.5, patience=3)
3. Graficar curvas de accuracy y loss
4. Comparar con CNN Base: ¿mejoró? ¿se redujo el overfitting? Justificar en un párrafo

SECCIÓN E — Comparación de Optimizadores

1. Entrenar la misma arquitectura con al menos 2 optimizadores distintos (SGD, Adam, RMSprop)
2. Graficar val_accuracy de los optimizadores en un mismo gráfico
3. Análisis: ¿cuál converge más rápido? ¿cuál alcanza mejor resultado? Explicar en un párrafo

SECCIÓN F — Evaluación Rigurosa (sobre test)

1. Accuracy global en test con la CNN Mejorada
2. Classification report con precision, recall, F1 por clase
3. Matriz de confusión con heatmap (con nombres de clases)
4. Curvas ROC por clase (One-vs-Rest) con AUC por clase
5. Identificar las 3 confusiones más frecuentes y explicar por qué ocurren (similitud visual)
6. Análisis de errores visual: mostrar al menos 10 imágenes mal clasificadas con clase real y predicha

SECCIÓN G — Conclusiones (celda markdown)

1. Resumen de resultados: accuracy final, mejores y peores clases
2. Impacto de la regularización (comparación CNN Base vs Mejorada)
3. Análisis de las confusiones más frecuentes y posibles causas
4. Lecciones aprendidas por el grupo
5. Limitaciones y posibles mejoras

2.2. REPOSITORIOS RECOMENDADOS — ACTIVIDAD 2

Cada grupo elige libremente un dataset de clasificación de imágenes de cualquier fuente pública confiable. A continuación, se listan repositorios recomendados:

Repositorio	URL	Descripción
TensorFlow Datasets	tensorflow.org/datasets	Colección oficial de datasets listos para tf.data; incluye imagen, texto y audio
Keras Datasets	keras.io/api/datasets	Datasets clásicos integrados en Keras (CIFAR, MNIST, Fashion-MNIST, etc.)
Kaggle Datasets	kaggle.com/datasets	Miles de datasets de imagen; filtrar por 'Image Classification'
Papers With Code — Datasets	paperswithcode.com/datasets	Datasets de benchmarks de investigación; filtrar por 'Image Classification'
Hugging Face Datasets	huggingface.co/datasets	Repositorio colaborativo; filtrar por tarea 'image-classification'
Roboflow Universe	universe.roboflow.com	Datasets de visión con múltiples formatos de descarga
torchvision.datasets	pytorch.org/vision/stable/datasets.html	Datasets de visión; se pueden descargar y cargar manualmente en TensorFlow
Google Dataset Search	datasetsearch.research.google.com	Buscador de datasets; buscar 'image classification dataset'

Requisitos mínimos del dataset: (a) Clasificación de imágenes; (b) al menos 1,000 imágenes en total; (c) al menos 3 clases; (d) datos reales (no sintéticos); (e) no utilizado en clase ni en los laboratorios (se excluyen MNIST y Fashion-MNIST).

Proceso de aprobación: Cada grupo comunica su dataset elegido al docente antes de la Sesión 06. El docente aprueba o solicita cambio para evitar duplicados entre grupos. Si dos grupos eligen el mismo dataset, tiene prioridad el que lo comunicó primero.

2.3. RÚBRICA DE EVALUACIÓN — ACTIVIDAD 2

Escala vigesimal (0–20). *Nota_Actividad2 = (Nota_Notebook × 0.70) + (Nota_Defensa × 0.30)*

2.3.1. Nota del Notebook (70%)

Criterio	Peso	Excelente (18–20)	Bueno (14–17)	Regular (11–13)	Deficiente (0–10)
EDA y preprocesamiento	15%	Grilla visual completa, distribución de clases, normalización y reshape correctos, split estratificado	Visualización básica, preprocesamiento correcto	Preprocesamiento incompleto (sin normalizar o sin reshape)	No preprocesa o no muestra visualizaciones
CNN Base	20%	Arquitectura correcta (≥2 bloques conv), summary completo, curvas de aprendizaje, diagnóstico de overfitting argumentado	Arquitectura correcta, curvas mostradas, diagnóstico breve	CNN que entrena con errores de diseño o sin diagnóstico	No implementa CNN o no entrena
CNN Mejorada	25%	≥3 técnicas (Aug+BN+Dropout+GAP), callbacks funcionales, comparación cuantitativa con CNN Base	2 técnicas de regularización, callbacks, comparación breve	1 técnica de regularización, sin callbacks	CNN idéntica a la base o con errores
Optimizadores	10%	≥2 optimizadores comparados en mismo gráfico, análisis de convergencia	2 optimizadores comparados sin análisis detallado	Solo 1 optimizador (sin comparación)	No compara optimizadores
Evaluación rigurosa	25%	Report + matriz + ROC por clase + análisis de errores visual + top confusiones explicadas	Report + matriz + al menos una métrica adicional	Solo accuracy global y matrix básica	Sin evaluación o solo accuracy
Calidad del código	5%	Ejecutable sin errores, comentado, markdown limpio, reproducible	Ejecutable con comentarios parciales	Errores menores al ejecutar	No ejecuta

2.3.2. Nota de la Defensa Oral (30%)

Criterio	Peso	Excelente (18–20)	Bueno (14–17)	Regular (11–13)	Deficiente (0–10)
Dominio técnico DL	50%	Todos explican la arquitectura, decisiones de diseño y evaluación con propiedad	Respuestas correctas con dudas en conceptos avanzados	Respuestas parciales, confusión entre técnicas	No demuestra comprensión de DL
Claridad de exposición	30%	Presentación fluida, estructurada, uso	Presentación clara con algunas imprecisiones	Presentación desorganizada	No logra comunicar el trabajo

		efectivo de visualizaciones			
Respuesta a preguntas	20%	Responde con ejemplos del propio trabajo y justificación técnica	Responde correctamente la mayoría	Respuestas vagas	No responde o responde incorrectamente

Nota individual: *Si en la defensa un integrante no demuestra participación real, el docente puede ajustar su nota individual hasta 5 puntos por debajo de la nota grupal.*

2.4. BANCO DE PREGUNTAS ORIENTATIVAS — DEFENSA ACT. 2

i. ¿Cuántos parámetros tiene su CNN? ¿Dónde se concentran la mayoría (capas conv o dense)?
ii. ¿Qué es y para qué sirve el padding='same'? ¿Qué pasaría sin él?
iii. Expliquen qué hace Batch Normalization y por qué se coloca antes de la activación.
iv. ¿Por qué Global Average Pooling reduce el overfitting comparado con Flatten + Dense?
v. ¿Qué transformaciones aplicaron en Data Augmentation y por qué tienen sentido para su dataset?
vi. ¿Cuáles son las clases que más confunde su modelo? ¿Por qué creen que ocurre?
vii. ¿Qué pasaría si entrenaran sin EarlyStopping? ¿Y sin ReduceLROnPlateau?
viii. Si pudieran usar transfer learning, ¿qué modelo preentrenado elegirían y por qué?
ix. ¿Cómo interpretan las curvas ROC por clase? ¿Qué indica un AUC bajo en una clase específica?
x. ¿Qué harían distinto si pudieran repetir el proyecto con más tiempo y recursos?

UNIVERSIDAD NACIONAL DEL CENTRO DEL PERÚ

FACULTAD DE INGENIERÍA DE SISTEMAS

DISPOSICIONES GENERALES

CRONOGRAMA

Fecha	Evento
Sesión 04 o 05	Publicación de la consigna (ambas actividades). Los grupos eligen sus datasets
Sesión 07	Fecha límite de entrega de ambos notebooks (.ipynb) vía aula virtual
Sesión 08	Defensa oral presencial (Actividades 1 y 2 consecutivas)

DISTRIBUCIÓN DEL TIEMPO — SESIÓN 08

Bloque	Tiempo
Instrucciones y sorteo de orden	5 min
Defensas Actividad 1 (6 grupos × 15 min)	90 min
Receso	10 min
Defensas Actividad 2 (6 grupos × 15 min)	90 min
Cierre y retroalimentación general	15 min
TOTAL ESTIMADO	~210 min (3.5 horas)

Nota: *Si el tiempo es insuficiente, se puede reducir a 10 min por grupo (6 min exposición + 4 min preguntas = 120 min total), o dividir las defensas en dos sesiones.*

FORMATO DE DEFENSA

Aspecto	Detalle
Duración por grupo	15 minutos máximo (8 min exposición + 7 min preguntas) por actividad
Medio	Proyección del notebook en Colab (el grupo ejecuta en vivo si se le solicita)
Orden	Sorteo al inicio de la sesión; mismo orden para ambas actividades
Preguntas	Cada integrante debe responder al menos 1 pregunta individualmente
Materiales permitidos	Solo el notebook entregado (no apuntes adicionales)

CÁLCULO DE LA NOTA FINAL DEL PARCIAL

Nota de cada actividad:

$$\text{Nota_Actividad} = (\text{Nota_Notebook} \times 0.70) + (\text{Nota_Defensa} \times 0.30)$$

Nota final del examen parcial:

Nota_Parcial = (Nota_Actividad1 × 0.50) + (Nota_Actividad2 × 0.50)

CONSIDERACIONES ÉTICAS Y ACADÉMICAS

- Los notebooks deben ser trabajo original del grupo. Se verificará similitud con herramientas de detección de plagio y comparación entre grupos.
- Está permitido consultar documentación oficial (Scikit-learn, TensorFlow, Keras, pandas, matplotlib), tutoriales y los notebooks de clase (incluidos los notebooks integradores Versión A y Versión B).
- No está permitido copiar soluciones completas de internet, usar el notebook de otro grupo, ni usar herramientas de IA generativa para producir el código completo (sí para consultas puntuales de sintaxis o depuración).
- Todos los integrantes deben poder explicar todo el código en la defensa.