

INTELIGENCIA ARTIFICIAL

Jaime Huaytalla Pariona, MsC
jhuaytalla@uncp.edu.pe

Contenidos



01

Machine Learning

Introducción a Inteligencia Artificial y Aprendizaje Supervisado

02

Aprendizaje Supervisado: Regresión

Redes Neuronales aplicado a problemas de regresión

03

Aprendizaje Supervisado: Clasificación

Redes Neuronales aplicado a problemas de clasificación

04

Deep Learning

Introducción a Redes Neuronales Convolucionales

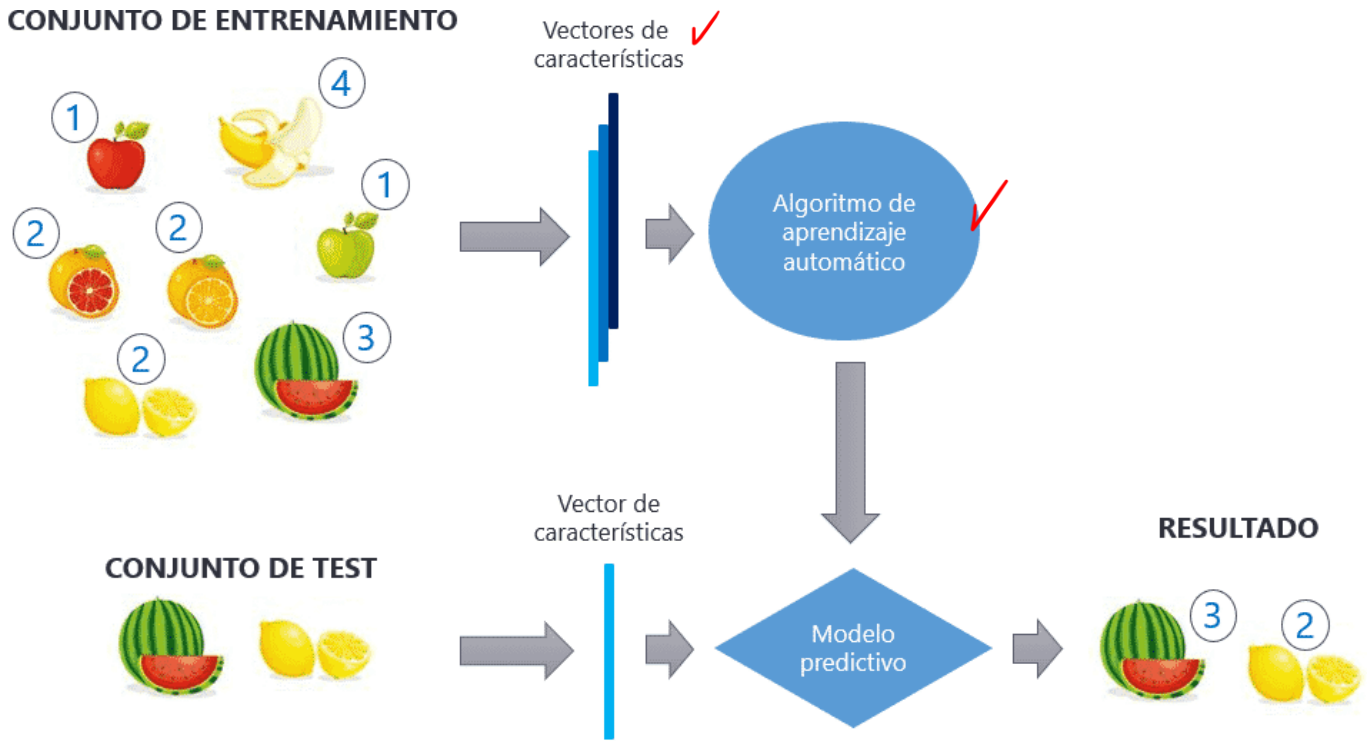
Aprendizaje Supervisado



1. Aprendizaje Supervisado: Regresión
2. Regresión Lineal y Métricas
3. Redes Neuronales
4. Modelo de Representación
5. Función de Costo y Gradiente Descendiente

Aprendizaje Supervisado

En el aprendizaje supervisado, se nos da un conjunto de datos y ya sabemos cómo debería ser nuestra salida correcta, teniendo la idea de que existe una relación entre la entrada y la salida. Los problemas de aprendizaje supervisado se clasifican en problemas de "regresión" y "clasificación".



Aprendizaje Supervisado

- En un problema de regresión, estamos tratando de predecir resultados dentro de una salida continua, lo que significa que estamos tratando de asignar variables de entrada a alguna función continua.
- En un problema de clasificación, estamos tratando de predecir los resultados en una salida discreta. En otras palabras, estamos tratando de mapear variables de entrada en categorías discretas.



PERFIL DE ESTUDIANTE

CLASIFICACIÓN

Predicción

APRUEBA O DESAPRUEBA



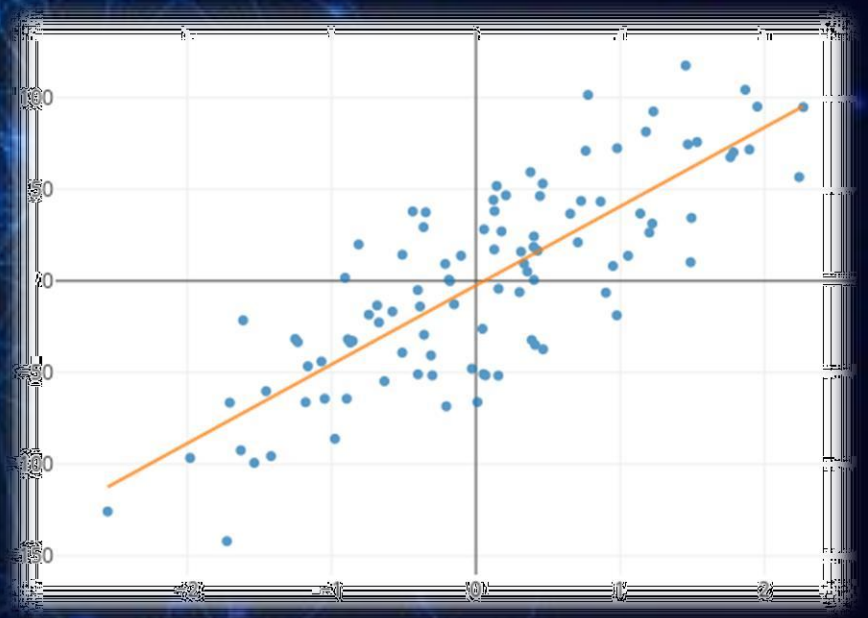
PERFIL DE ESTUDIANTE

REGRESIÓN

Predicción de notas

PORCENTAJE

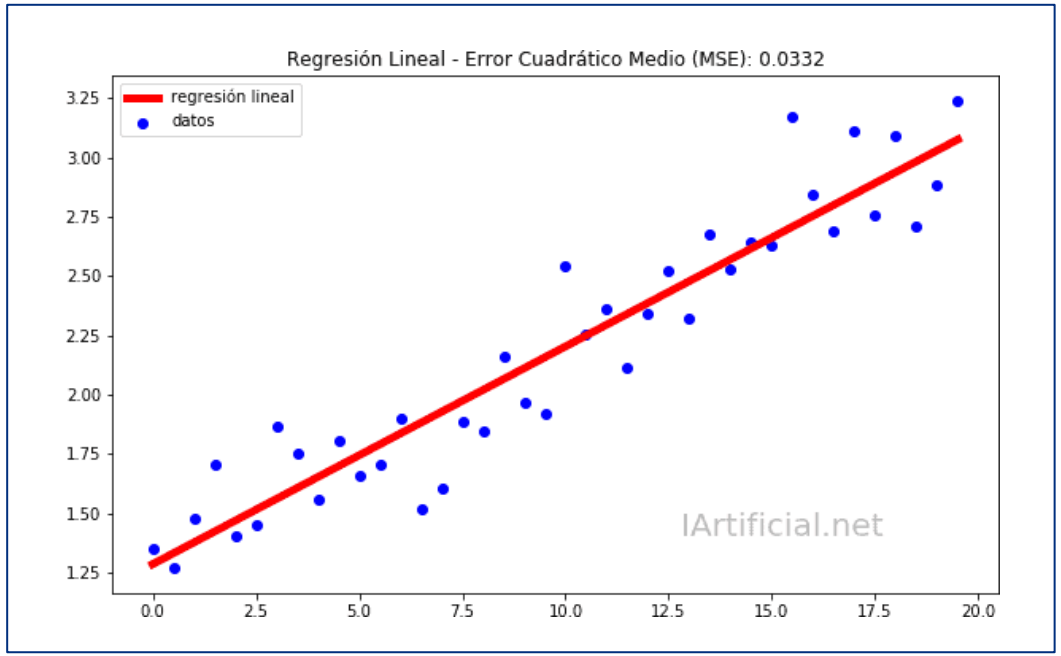
Aprendizaje supervisado
Regresión



TECHNOLOGY
BACKGROUND

Aprendizaje supervisado: Regresión

En un problema de regresión, estamos tratando de predecir resultados dentro de una salida continua, lo que significa que estamos tratando de asignar variables de entrada a alguna función continua.



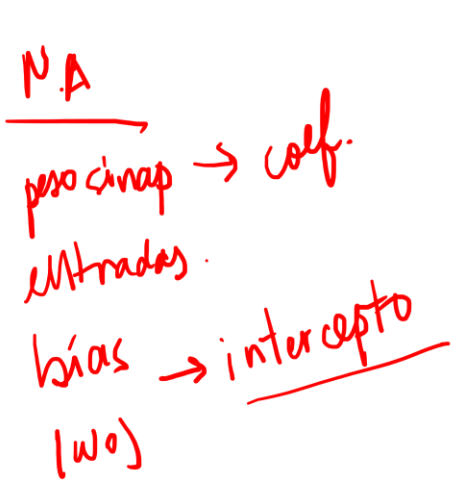
Aprendizaje supervisado: Regresión

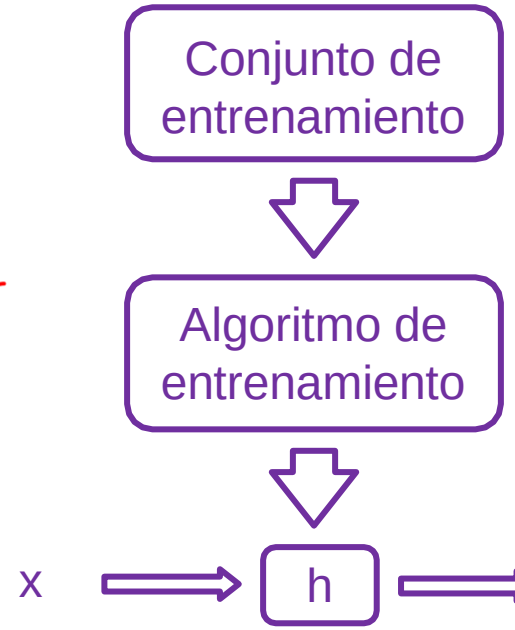
OBJETIVO: Predecir un valor numérico



Regresión Lineal Multivariables

La regresión lineal con múltiples variables también se conoce como "regresión lineal multivariante". La forma multivariable de la función de hipótesis que acomoda estas múltiples características es la siguiente:





Obj: Calcular θ_0 y θ_i para y (salida) sea lo más cercana a la real.

Modelo M.L.

Hipótesis

coeficiente

$$h_\theta(x) = \underset{w_0}{\theta_0} + \underset{w_1}{\theta_1 x_1} + \underset{w_2}{\theta_2 x_2} + \underset{w_3}{\theta_3 x_3} + \cdots + \theta_n x_n$$

Intercepto

entr.

Métricas de Regresión

MEAN SQUARE ERROR (mse)

El error cuadrático medio de un estimador mide el promedio de los errores al cuadrado:

$$\text{MSE} = \frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2$$

$n \rightarrow$ nro de datos
$y \rightarrow$ salida real
$\hat{y} \rightarrow$ salida predicción

ROOT MEAN SQUARE ERROR

Representa la desviación estándar de la muestra de las diferencias entre los valores predichos y los valores observados (llamados residuos).

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{j=1}^{n}(y_j - \hat{y}_j)^2}$$

Métricas de Regresión

MEAN ABSOLUTE ERROR

MAE es el promedio de la diferencia absoluta entre los valores predichos y el valor observado. El MAE es una puntuación lineal, lo que significa que todas las diferencias individuales se ponderan por igual en la media.

$$\mathrm{MAE} = \frac{1}{n}\sum_{j=1}^{n}|y_j - \hat{y}_j|$$

Métricas de Regresión

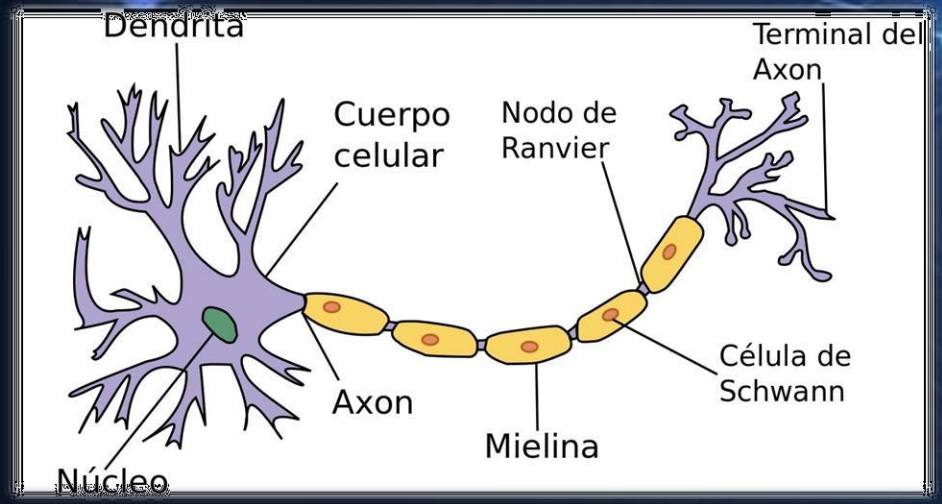
R Squared (R^2) and Adjusted R Squared

R Squared y R Squared adjusted se utilizan a menudo con fines explicativos y explican qué tan bien las variables independientes seleccionadas explican la variabilidad en las variables dependientes. Ambas métricas se malinterpretan bastante y, por lo tanto, me gustaría aclararlas primero antes de analizar sus pros y sus contras.

$$\hat{R}^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} = 1 - \frac{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \bar{Y})^2}$$

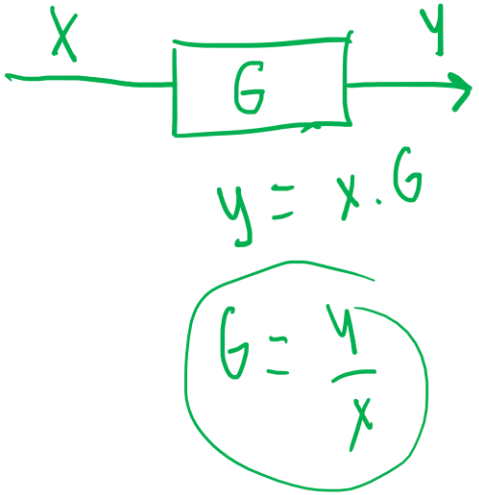
$$R^2_{adj} = 1 - \left[\frac{(1 - R^2)(n-1)}{n-k-1}\right]$$

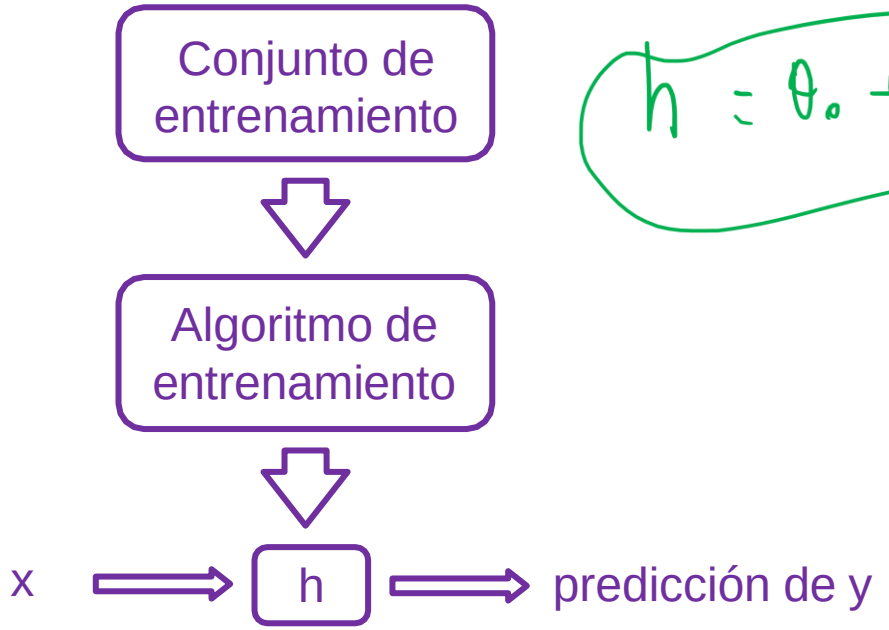
Redes Neuronales



Representación del Modelo

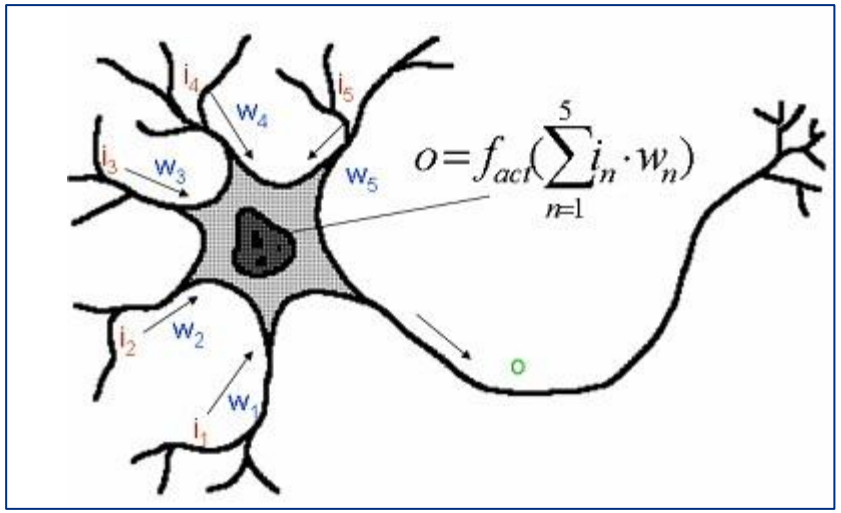
Para describir el problema de aprendizaje supervisado más formalmente, nuestro objetivo es, dado un conjunto de entrenamiento, aprender una función h : X → Y para que h(x) sea un "buen" predictor para el valor correspondiente de y. Por razones históricas, esta función h se llama hipótesis.



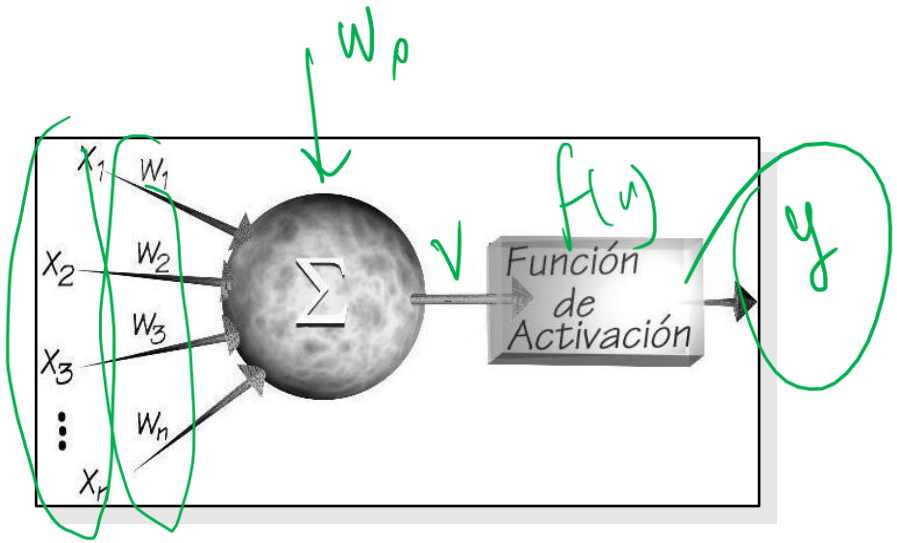


$h = \theta_0 + x_1\theta_1 + \dots + x_n\theta_n$

Redes Neuronales



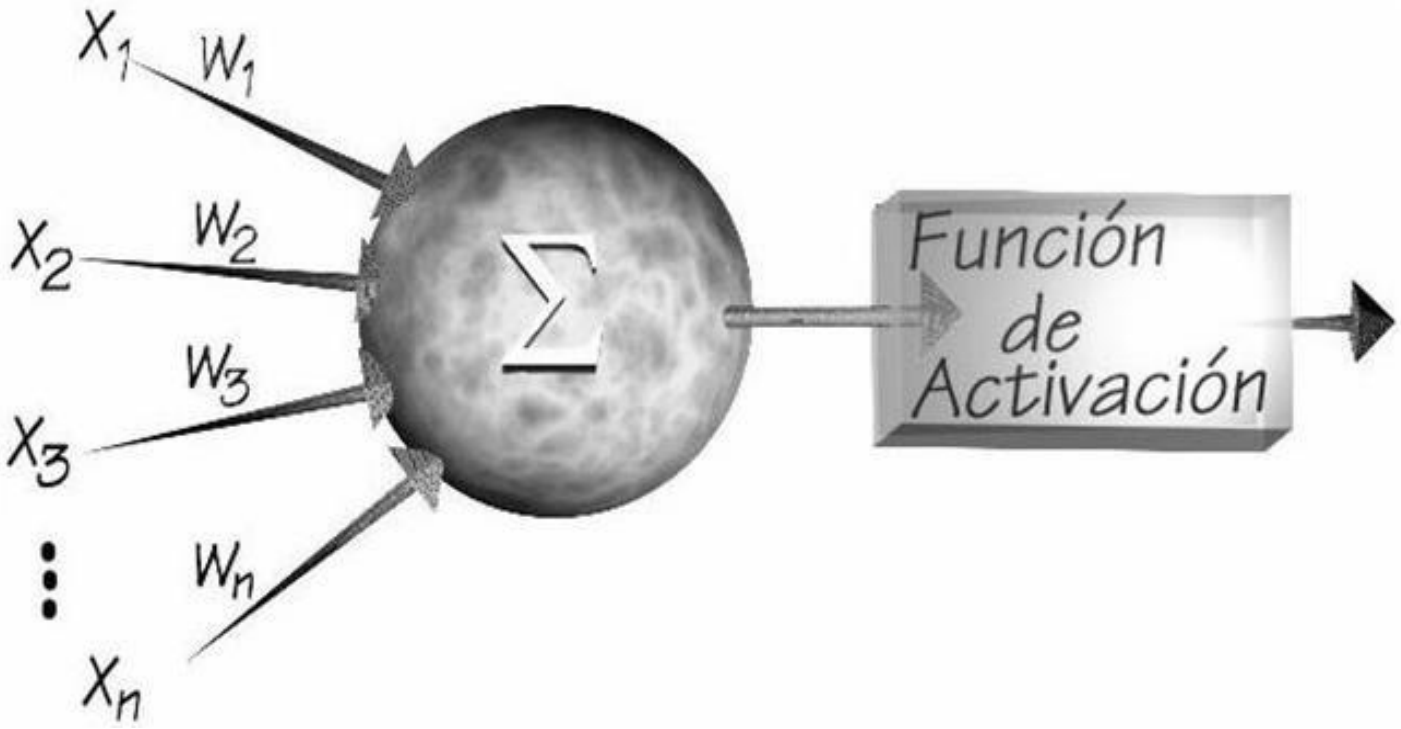
Una neurona biológica



Una neurona artificial

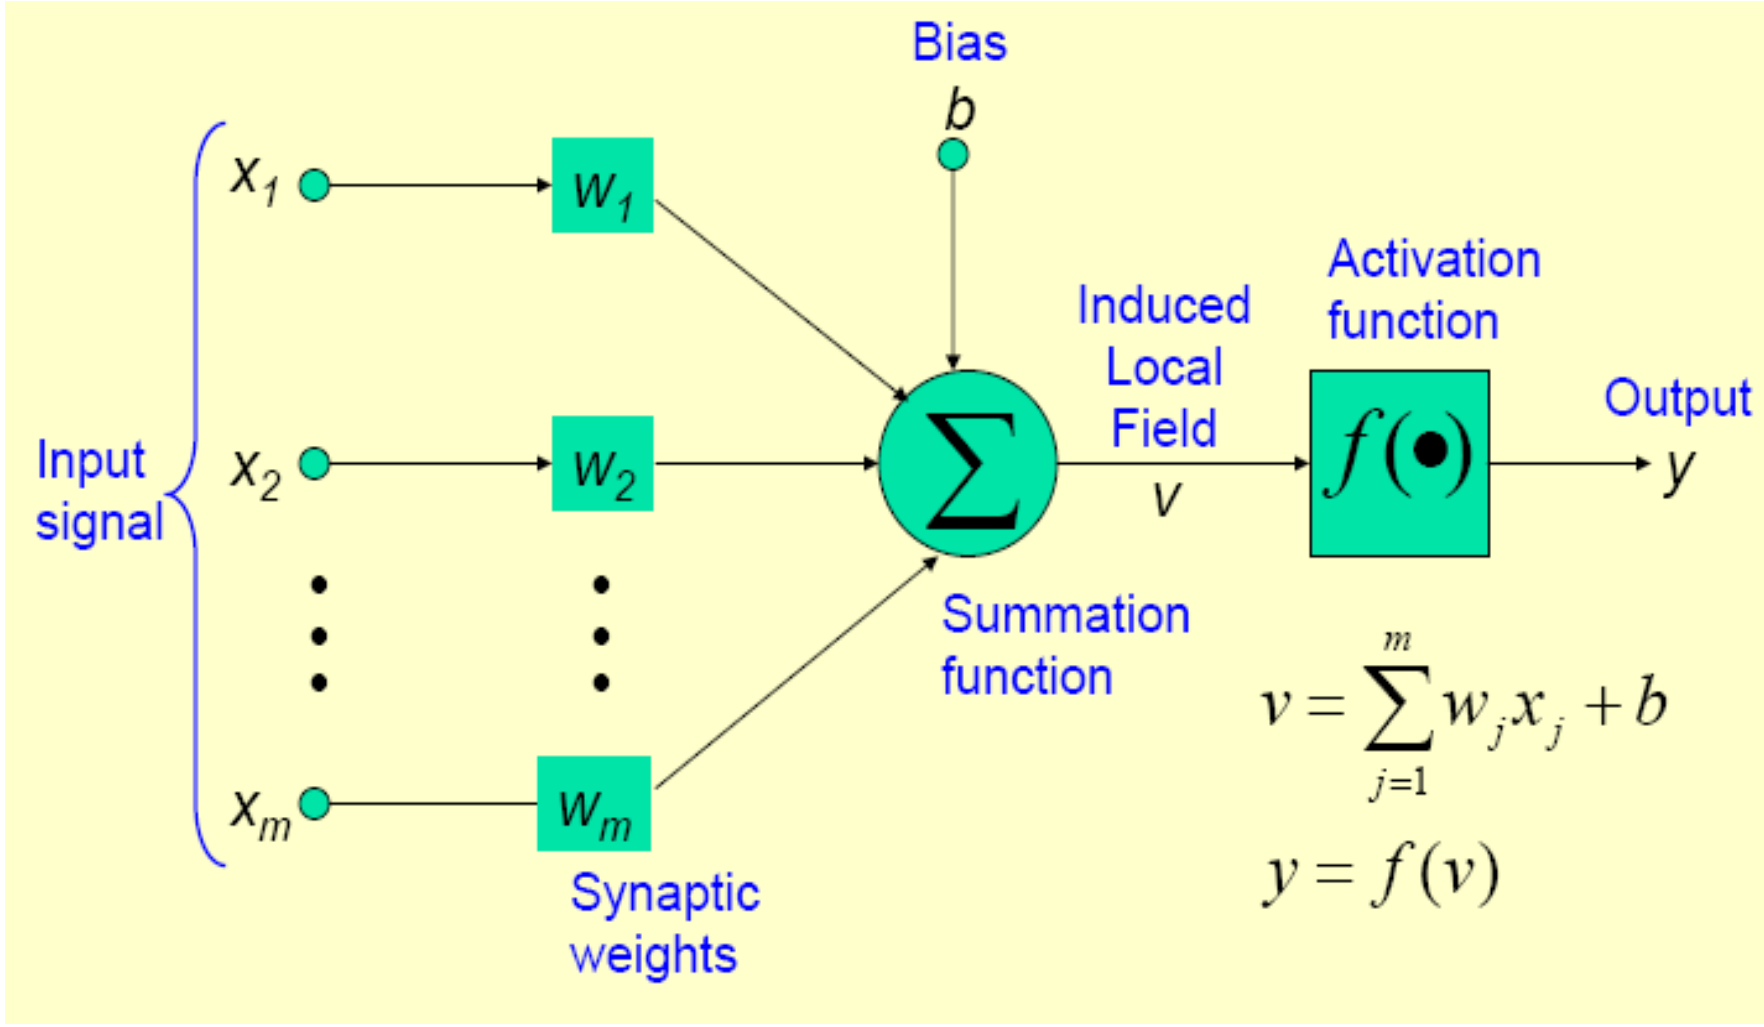
Neurona Artificial

Las neuronas son básicamente unidades computacionales que toman entradas (dendritas) como entradas eléctricas (llamadas "picos") que se canalizan hacia salidas (axones).



Modelo de McCulloch-Pitts (1949)

Neurona Artificial



Función de Costo

Podemos medir la precisión de nuestra función de hipótesis usando una función de costo. Esto toma una diferencia promedio (en realidad, una versión más elegante de un promedio) de todos los resultados de la hipótesis con entradas de x y la salida real de y.

$x(h) \rightarrow y$

int cuad.

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} (\hat{y}_i - y_i)^2 = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)^2$$

$\hat{y} = h_\theta(x_i)$

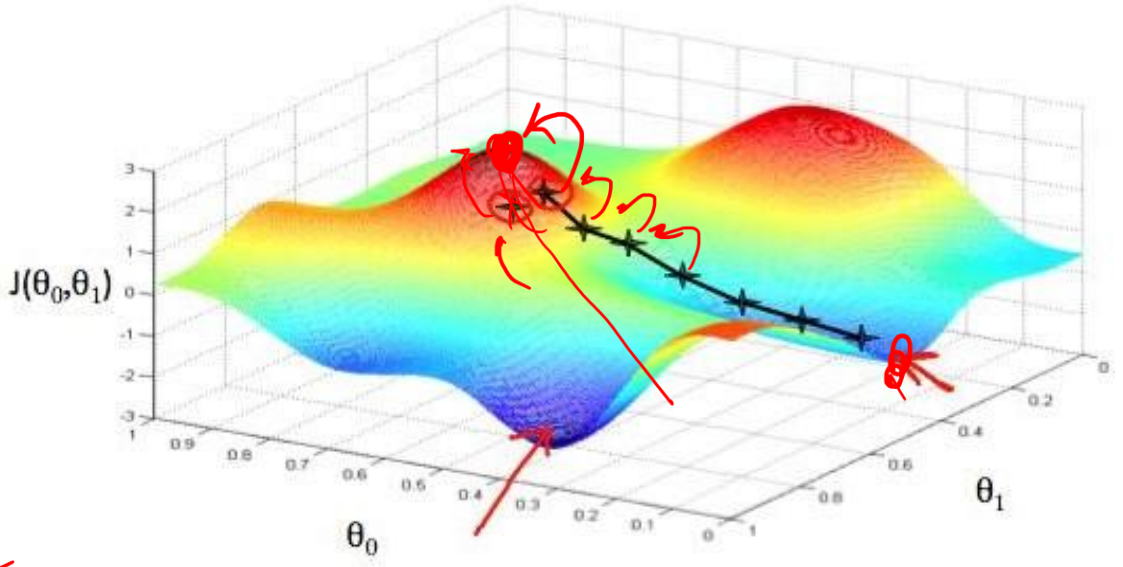
Esta función también se denomina "función de error cuadrático" o "error cuadrático medio".

(mse) → Det. que tan lejos me encuentro de la salida.

Gradiente Descendiente

α → Tasa de aprend. (paso)

La pendiente de la tangente es la derivada en ese punto y nos dará una dirección hacia donde movernos. Hacemos escalones hacia abajo de la función de costo en la dirección con el descenso más pronunciado. El tamaño de cada paso está determinado por el parámetro α, que se denomina tasa de aprendizaje.



El algoritmo de descenso de gradiente es:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

j+1 j

repetir hasta la convergencia

Donde j=0,1

Formula:

$$w_1 = w_0 - \alpha \cdot \frac{\partial J}{\partial w}$$

$$^{1}\omega_x = {}^{0}\omega_x - \alpha \frac{\partial J}{\partial \omega_x}$$

Épocas → Iteraciones

ω_0 → Random

epochs ↔ k

k_1:

$$^{1}\omega_0 = {}^{0}\omega_0 - \alpha \frac{\partial J}{\partial \omega_0}$$

$$^{1}\omega_1 = {}^{0}\omega_1 - \alpha$$

$$^{1}\omega_2 = {}^{0}\omega_2 - \alpha$$

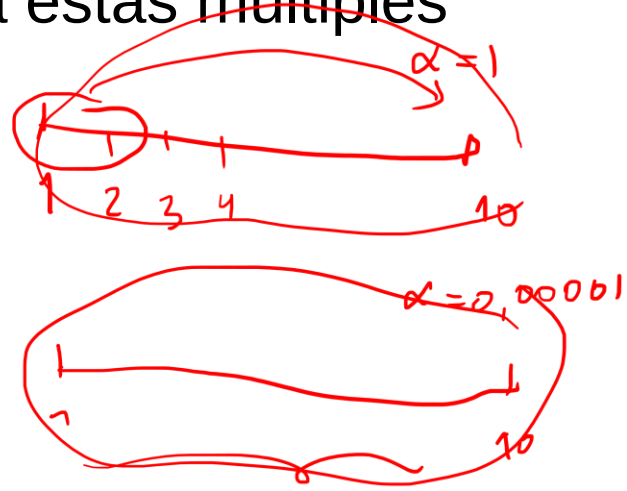
$$^{1}\omega_3 = {}^{0}\omega_3 - \alpha$$

h_1

Regresión Lineal Multivariables

La forma multivariable de la función de hipótesis que acomoda estas múltiples características es la siguiente:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \cdots + \theta_n x_n$$

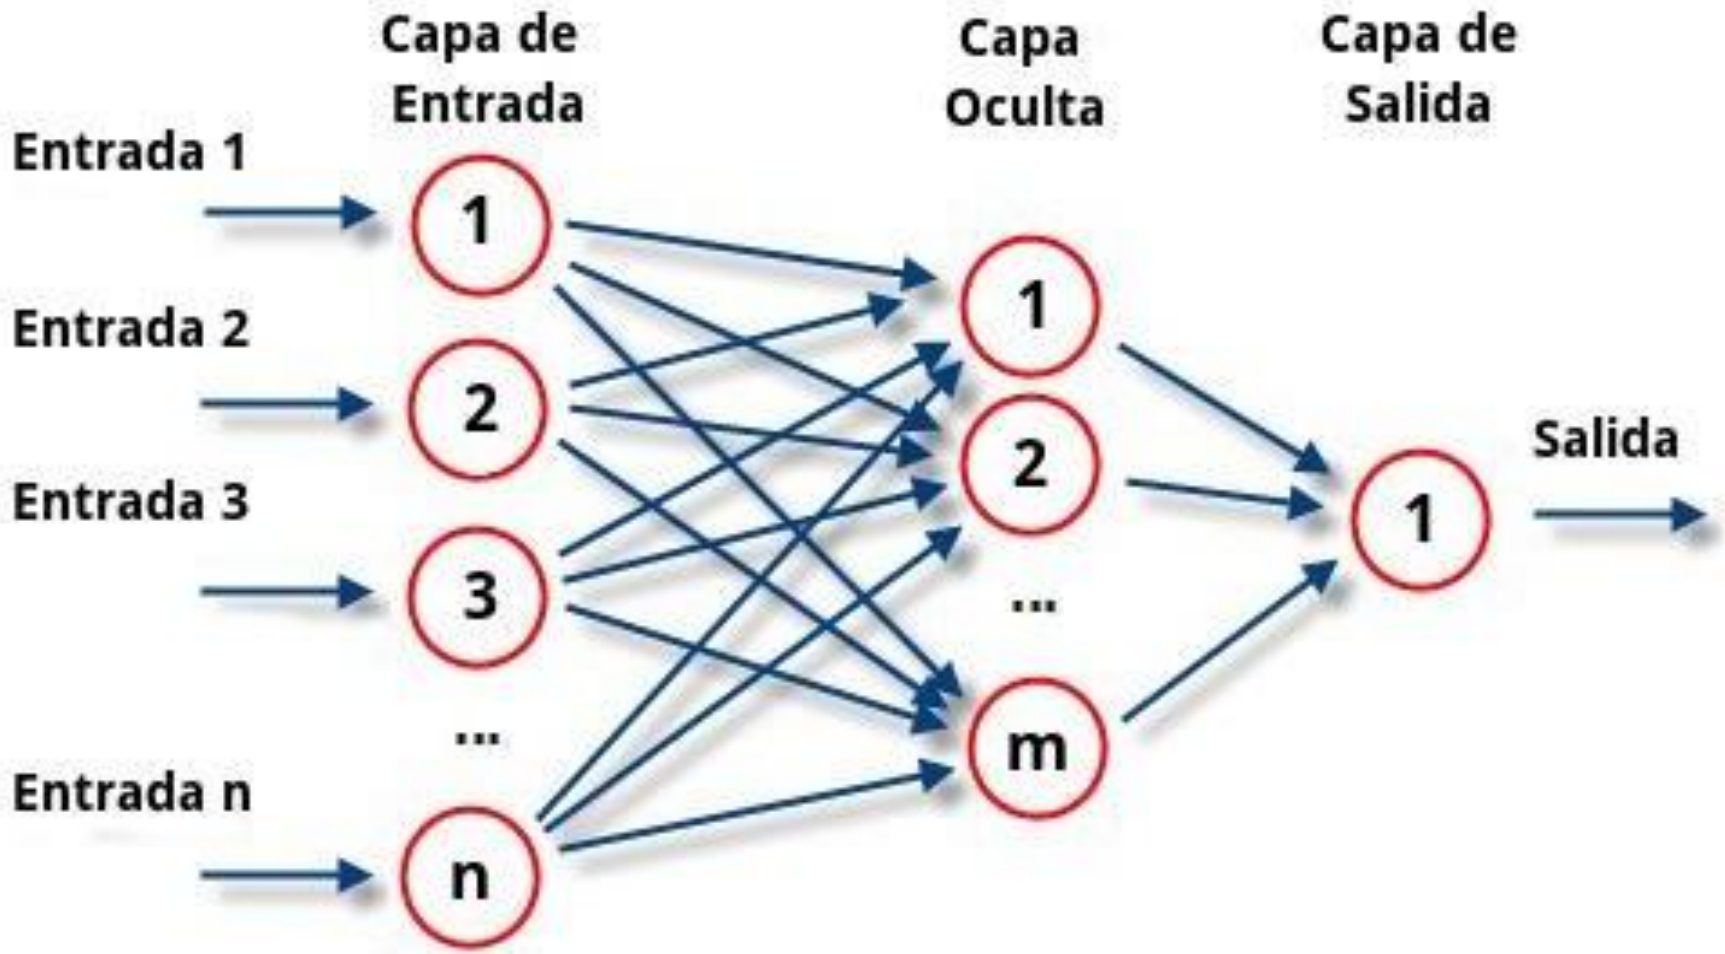


Gradiente Descendiente Multivariable:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} \qquad \text{for j} := 0...\text{n}$$

- α muy pequeño: convergencia lenta.
- α muy grande: puede no decrecer en cada iteración y puede no converger.

Redes Neuronales



Laboratorio: “Hola Mundo”

Se desea conocer el precio de una vivienda de 70 m2, teniendo los siguientes datos:

Tamaño(m2)	Precio($)
20	22000
30	35000
40	41000
50	52000
60	63000


Gracias