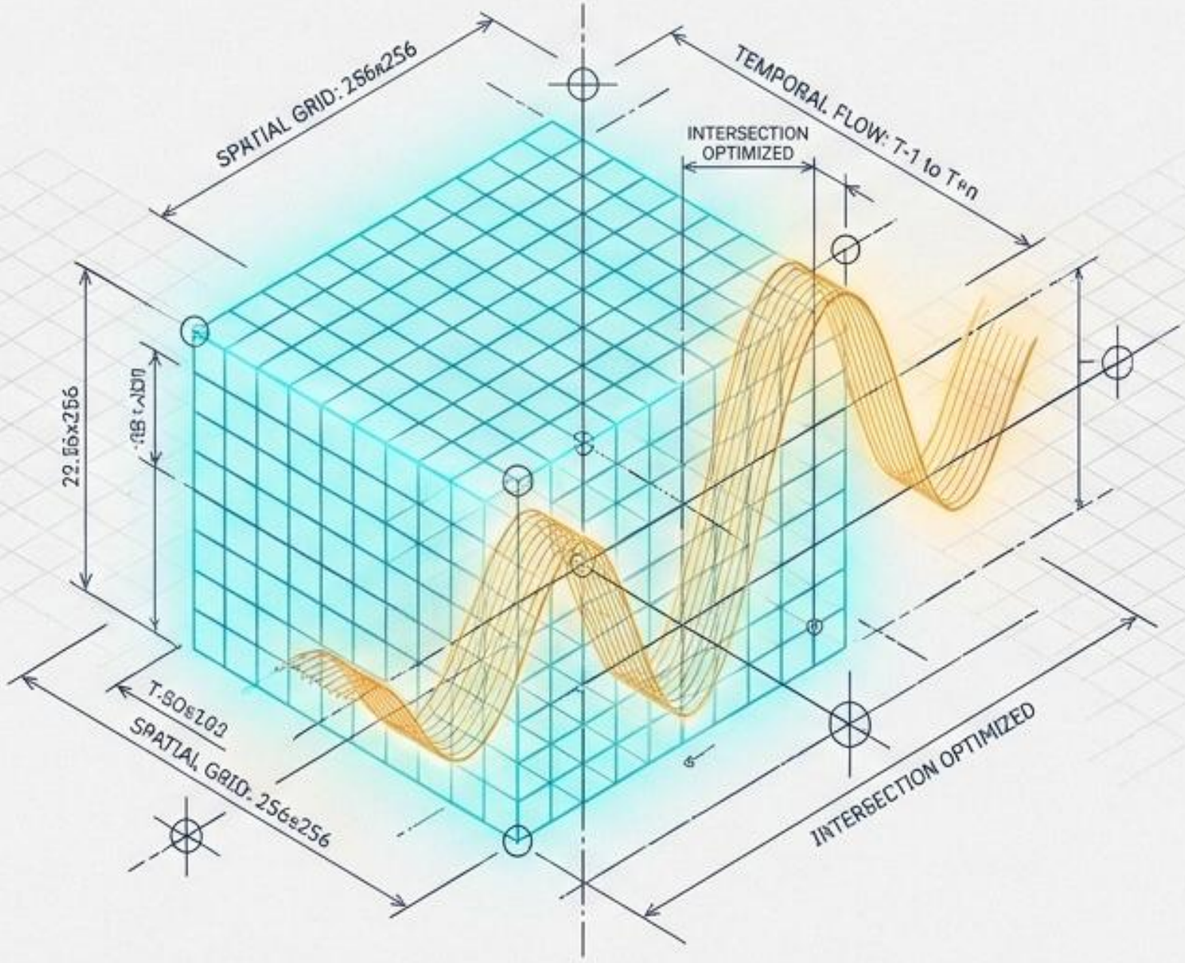
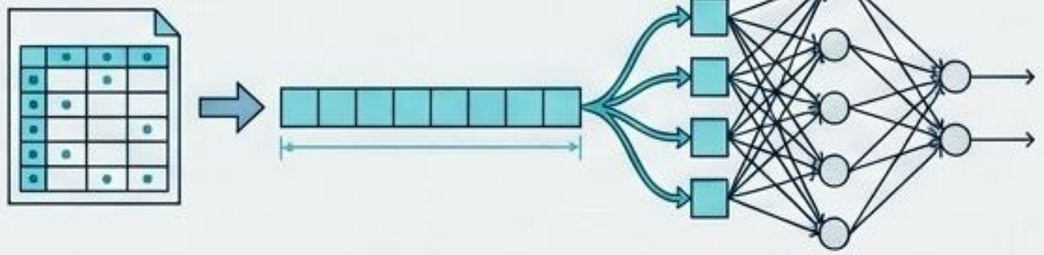


Redes Convolucionales y Recurrentes Aplicadas

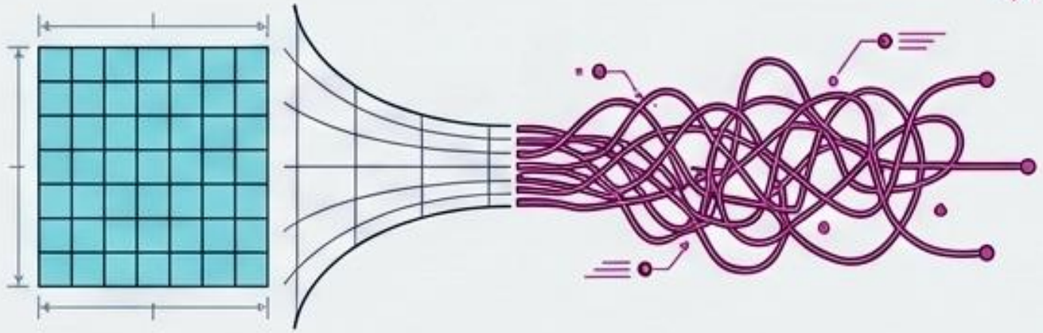
Visión, Memoria y Optimización en Deep Learning

Ingeniería de Sistemas - Unidad II



Perceptrón Multicapa (MLP)

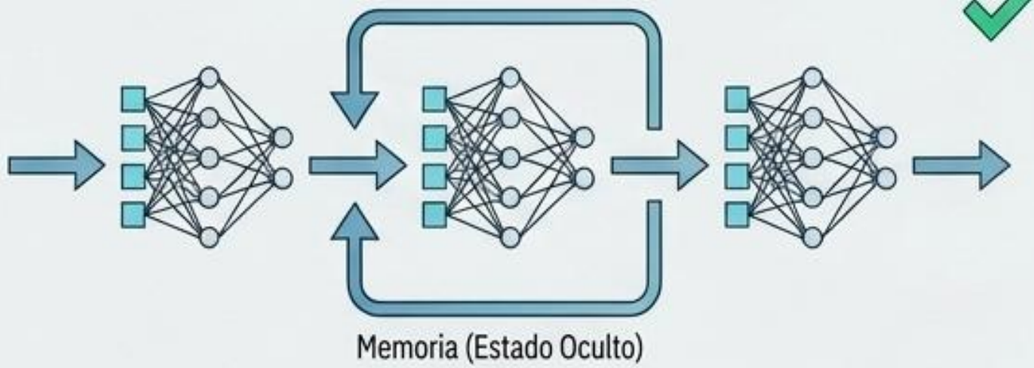
Perfecto para variables independientes y sin orden fisico.



Problema Espacial

Al aplanar una imagen, el MLP destruye la proximidad. Un pixel no sabe quién es su vecino.

Solución Temporal: Redes Recurrentes (RNN)



Las RNN procesan secuencias y mantienen una "memoria" del estado anterior, permitiendo entender el contexto y el orden temporal.



Problema Temporal

El MLP asume que cada entrada es aislada. No tiene noción del "ayer" ni memoria del orden cronológico.

El Problema: Explosión de Parámetros

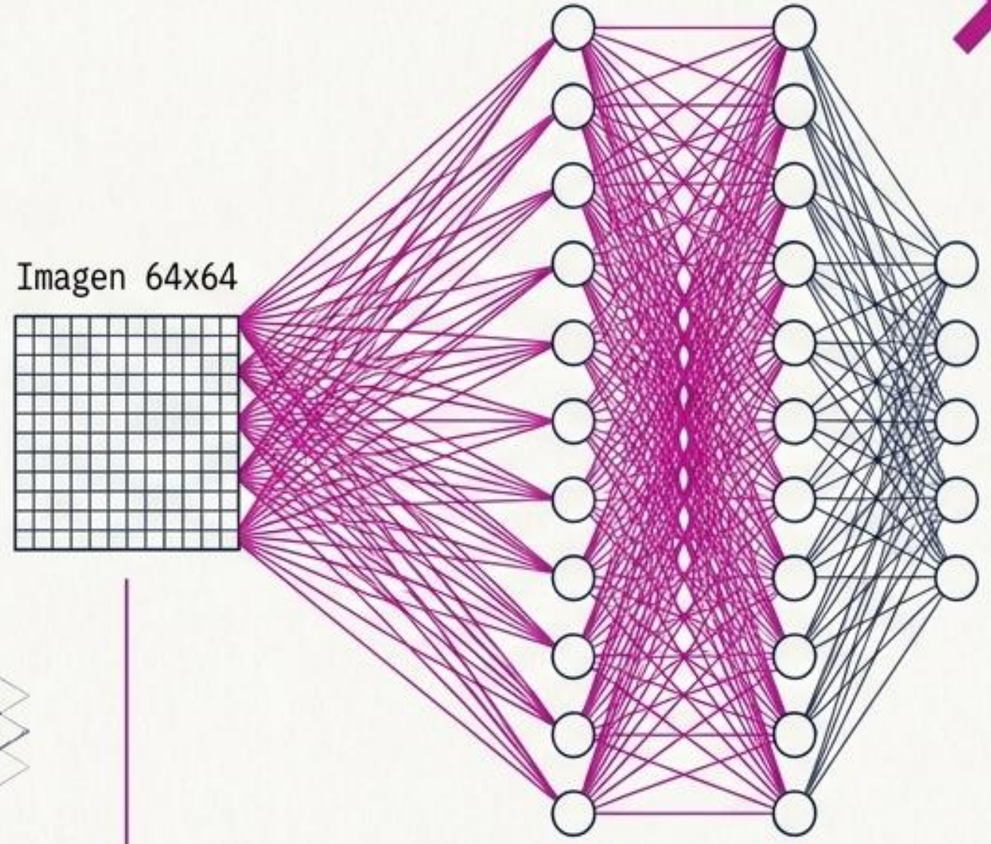
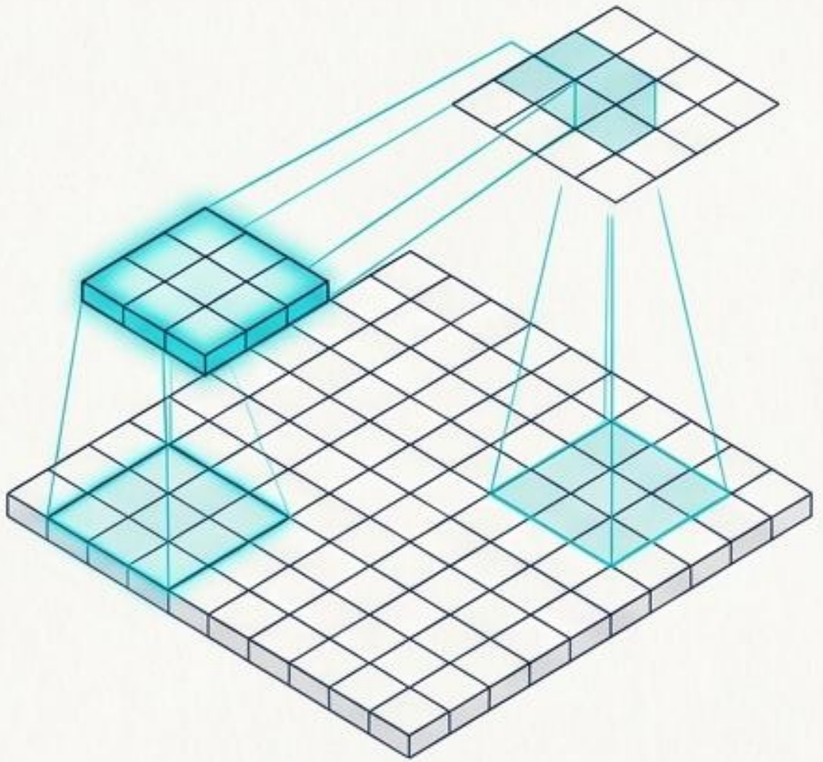


Imagen 64×64 = 12,288 entradas.

Conectarla a una capa oculta genera millones de parámetros innecesarios.

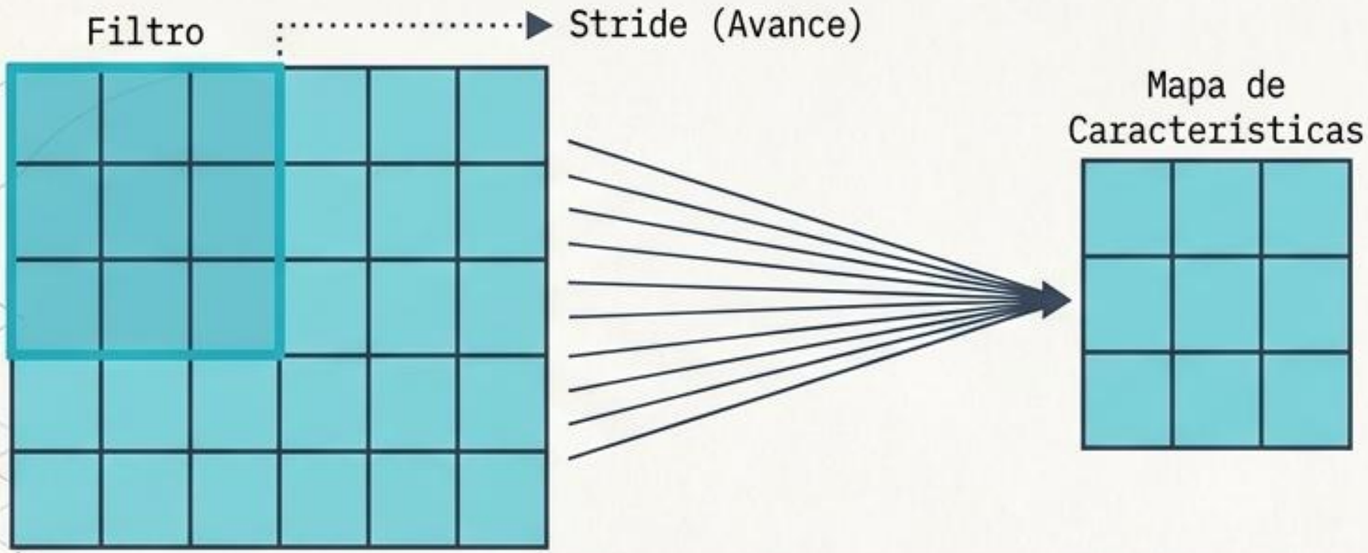
La Solución: Preservación Espacial CNN



Redes Convolucionales (CNN)

Mantiene la cuadrícula 2D. Utiliza filtros compartidos que se deslizan por toda la imagen, detectando patrones locales y reduciendo drásticamente el peso computacional.

Operación de Convolución

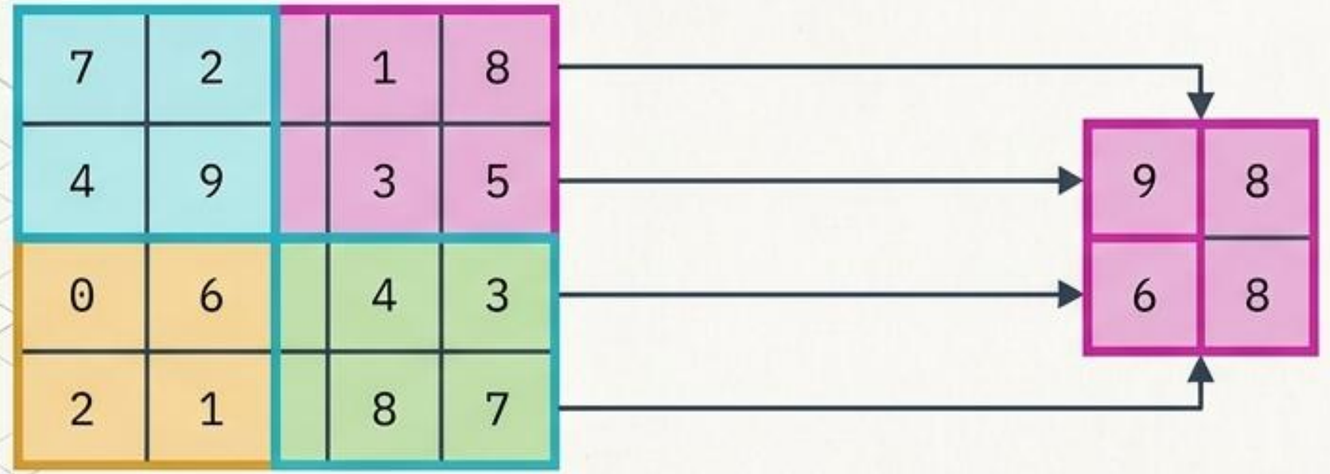


Kernel/Filtro: Matriz de pesos que aprende a detectar bordes o texturas.

Stride: Cuántos píxeles avanza el filtro en cada paso.

Padding: Relleno en los bordes para controlar el tamaño de salida.

Reducción Dimensional: Max Pooling



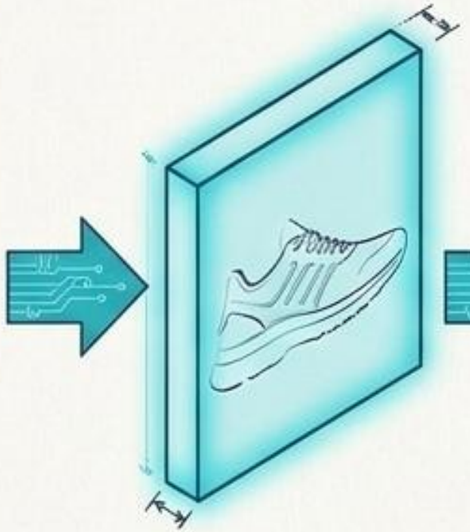
Extrae el valor máximo de cada bloque.
Reduce el cómputo y aporta tolerancia a pequeños desplazamientos del objeto.

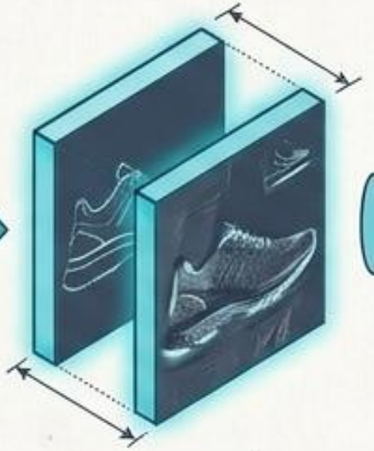
El Plano Digital: Arquitectura del Pipeline CNN

Entrada → Bloque de Extracción (Conv2D + Pooling) → Transición (Flatten) → Bloque de Clasificación (Dense)



Imagen 2D Raw

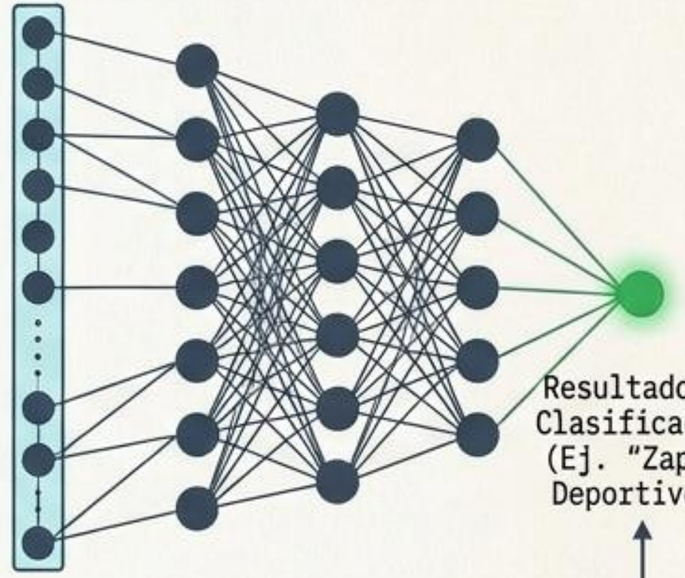




Mapas de Características
(Más profundos,
menos espaciales)



Vector Lineal
(1D)



Resultado de
Clasificación
(Ej. "Zapato
Deportivo")

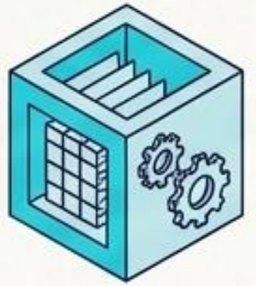
De bordes simples a formas complejas.

Core Principle Box

Las capas convolucionales extraen características visuales automáticamente; las capas densas las usan para clasificar.

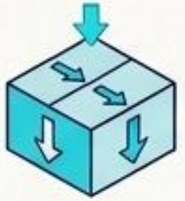
```python
modelo = keras.Sequential([
    layers.Conv2D(32, kernel_size=3, activation='relu'),
    layers.MaxPooling2D(pool_size=2),
    layers.Flatten(),
    layers.Dense(10, activation='softmax')
])

modelo.compile(loss='sparse_categorical_crossentropy')
```

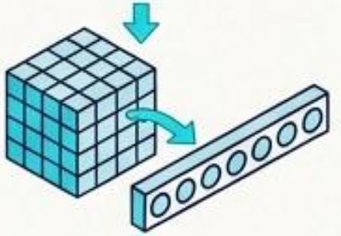


Conv2D
(32 filtros)

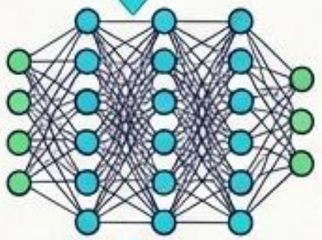
32 filtros aprendiendo patrones espaciales independientes.



MaxPooling2D (2x2)



Flatten



Dense
(10 unidades)

Dataset Fashion-MNIST: 70k imágenes. Al haber 10 clases (prendas), la salida requiere **softmax** para distribuir la probabilidad.

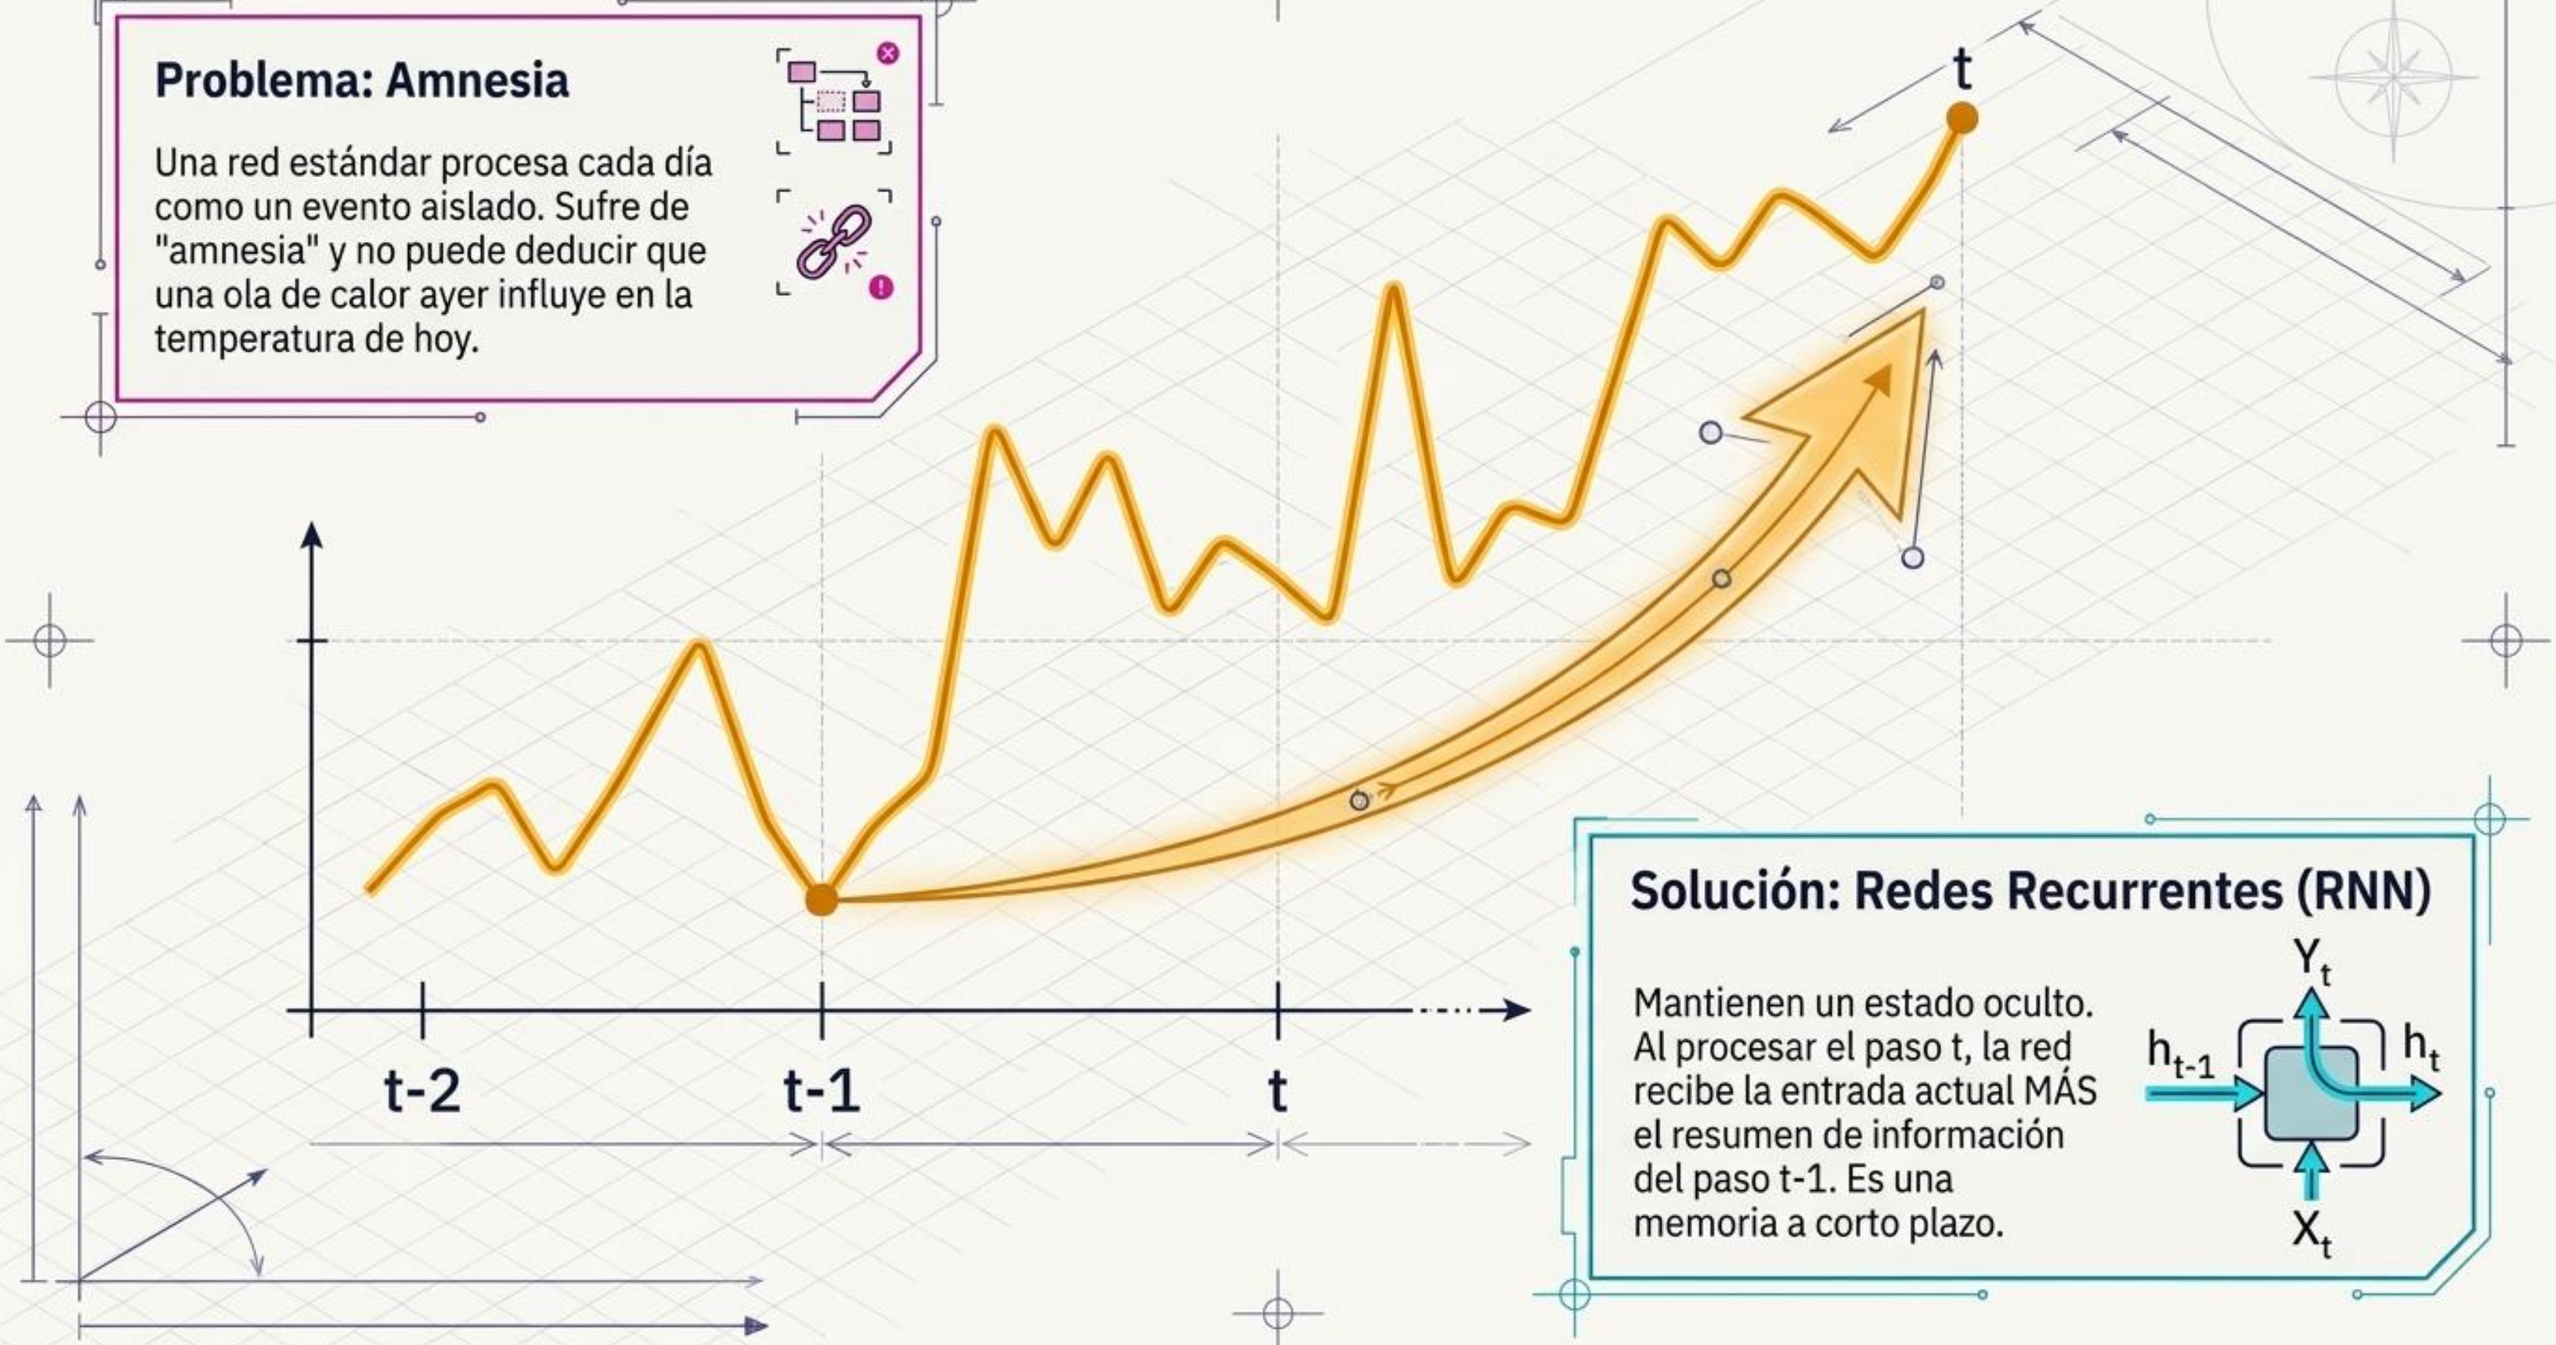




Usamos `sparse_categorical_crossentropy` porque las etiquetas son enteros (0-9), no vectores one-hot.

Problema: Amnesia

Una red estándar procesa cada día como un evento aislado. Sufre de "amnesia" y no puede deducir que una ola de calor ayer influye en la temperatura de hoy.

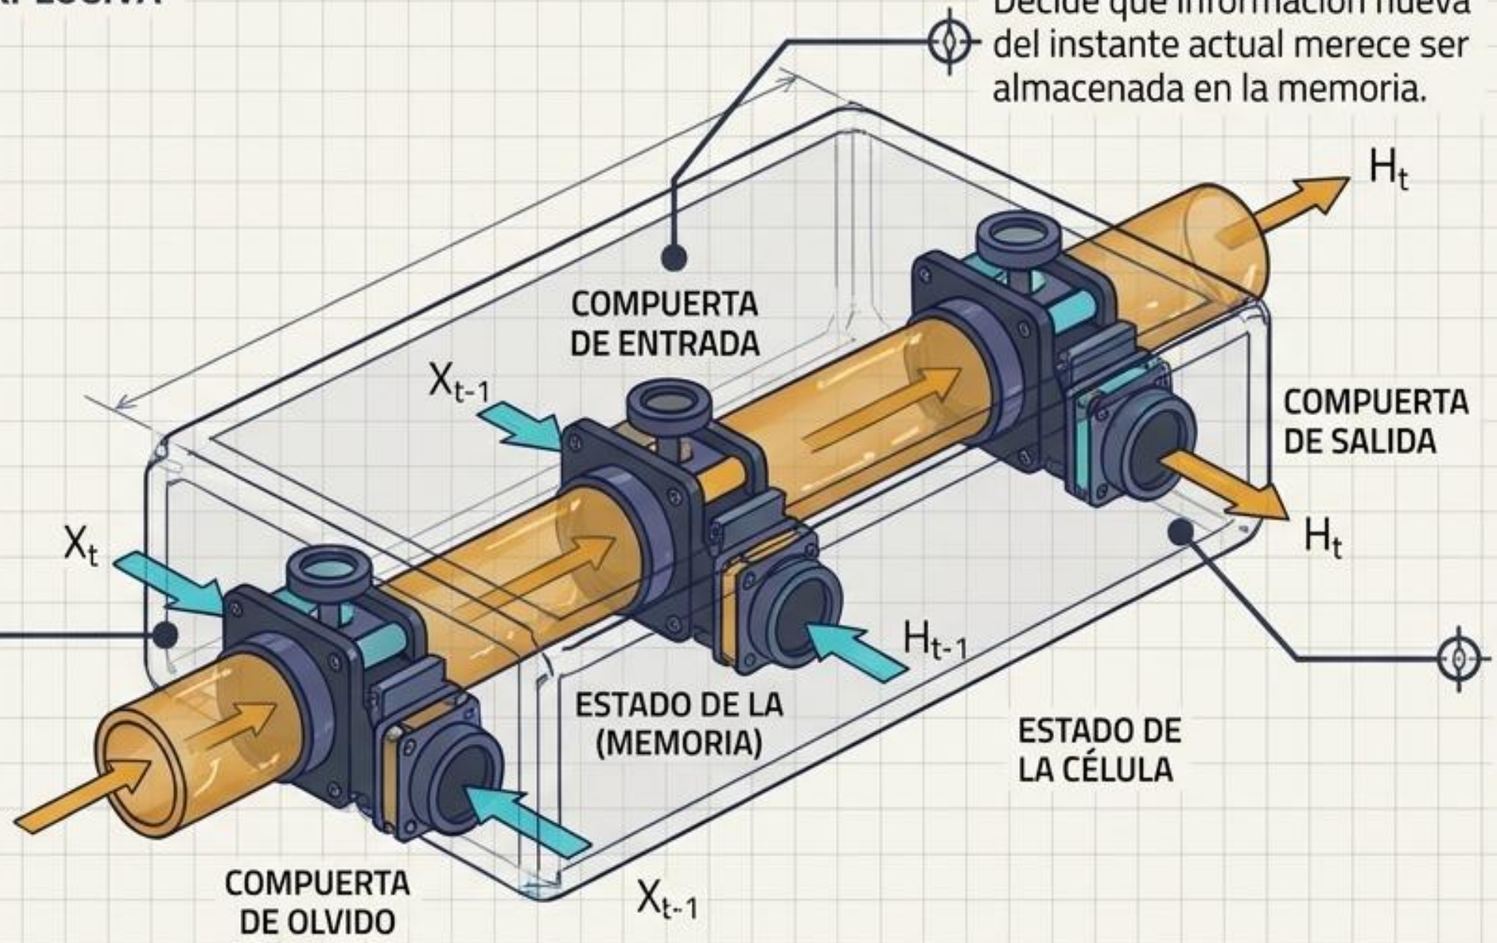


Solución: Redes Recurrentes (RNN)

Mantienen un estado oculto. Al procesar el paso t, la red recibe la entrada actual MÁS el resumen de información del paso t-1. Es una memoria a corto plazo.

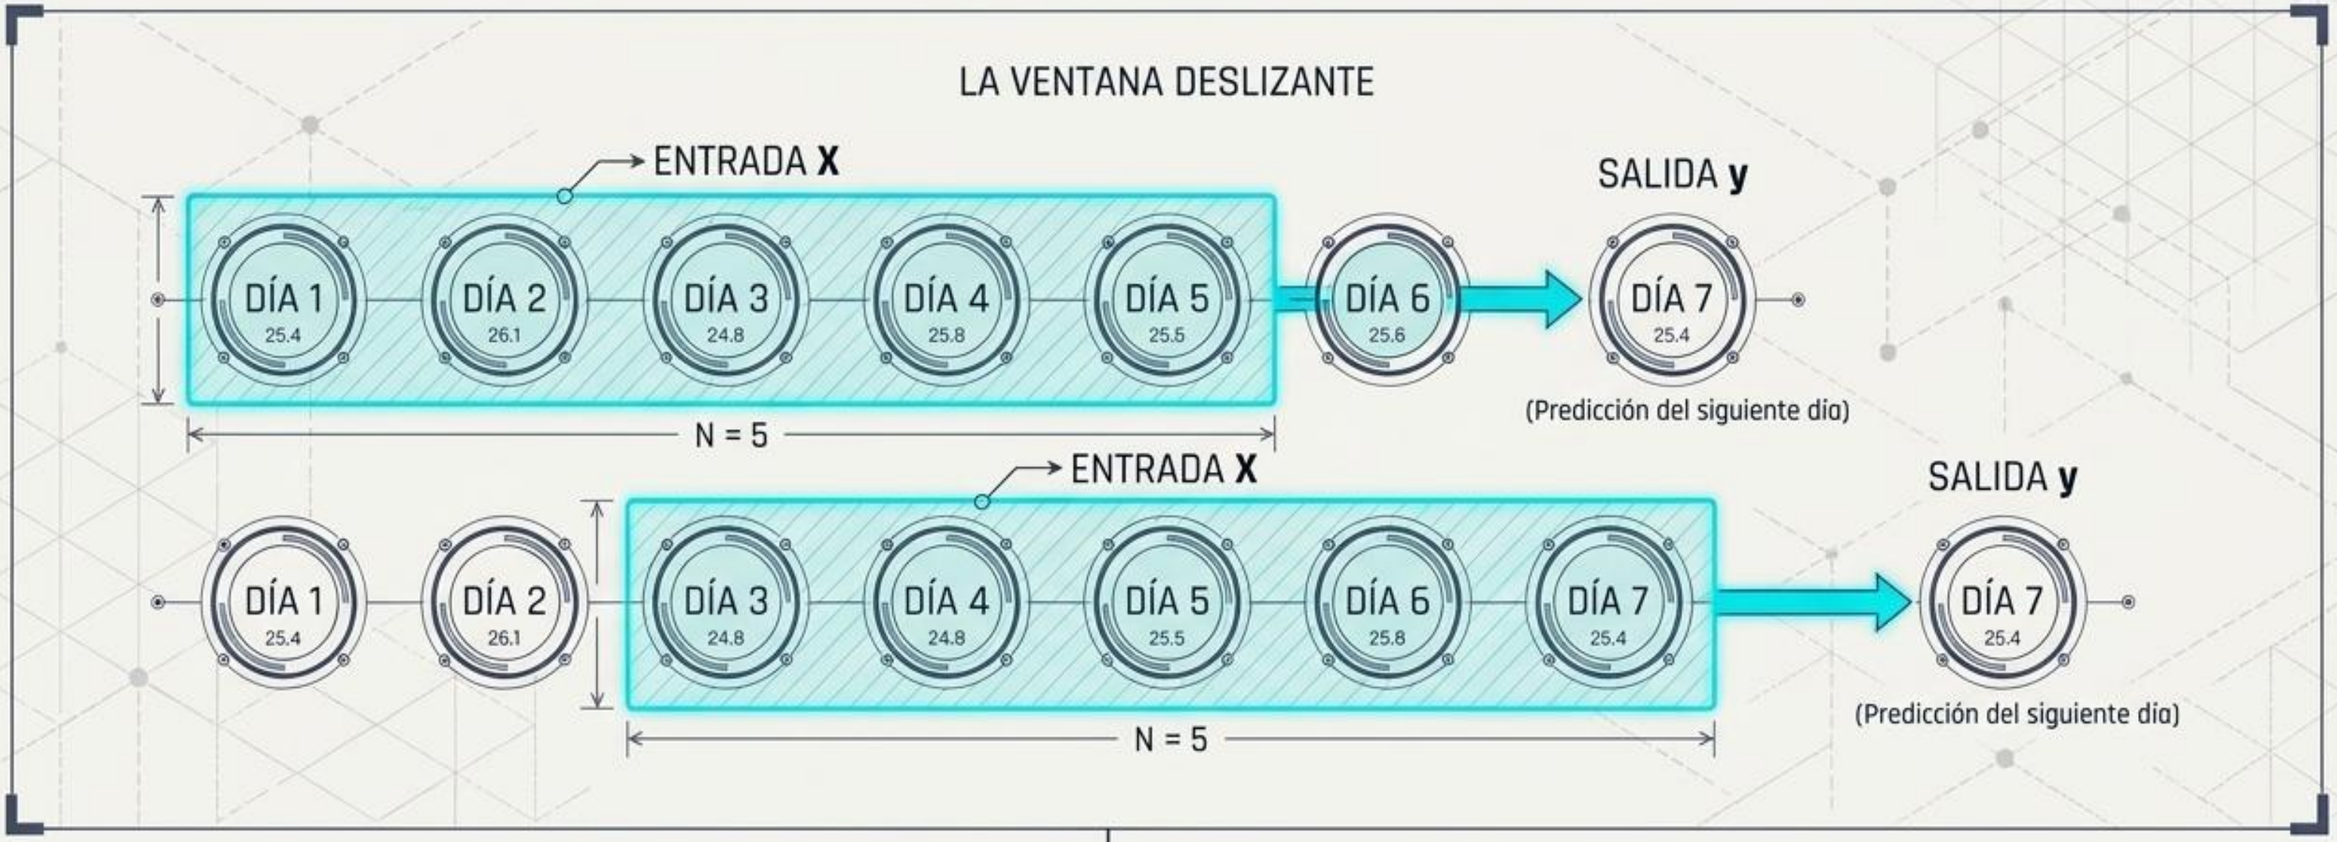
ARQUITECTURA DE LA CÉLULA LSTM

CÉLULA LSTM - VISTA EXPLOSIVA



Al tener control explícito sobre qué recordar y qué olvidar, las LSTM resuelven el problema del gradiente que se desvanece, permitiendo aprender secuencias largas.

TRANSFORMACIÓN DE DATOS: LA VENTANA DESLIZANTE




```
VENTANA = 5
for i in range(len(serie) - VENTANA):
    X.append(serie[i : i + VENTANA])
    y.append(serie[i + VENTANA])

X = np.array(X).reshape(-1, VENTANA, 1)
```

Transformamos una serie temporal continua en un problema de aprendizaje supervisado clásico: usamos los últimos N días para predecir el día siguiente. Keras exige un tensor 3D: (muestras, pasos_de_tiempo, características).

IMPLEMENTACIÓN Y EVALUACIÓN: EL MODELO LSTM

```
modelo_lstm = keras.Sequential([
    layers.Input(shape=(VENTANA, 1)),
    layers.LSTM(16, activation='tanh'),
    layers.Dense(1) # Sin activación
])

modelo_lstm.compile(
    loss='mse',
    metrics=['mae']
)
```

Problema de Regresión (predecir temperatura continua). La capa de salida no lleva función de activación (ni sigmoid ni softmax).

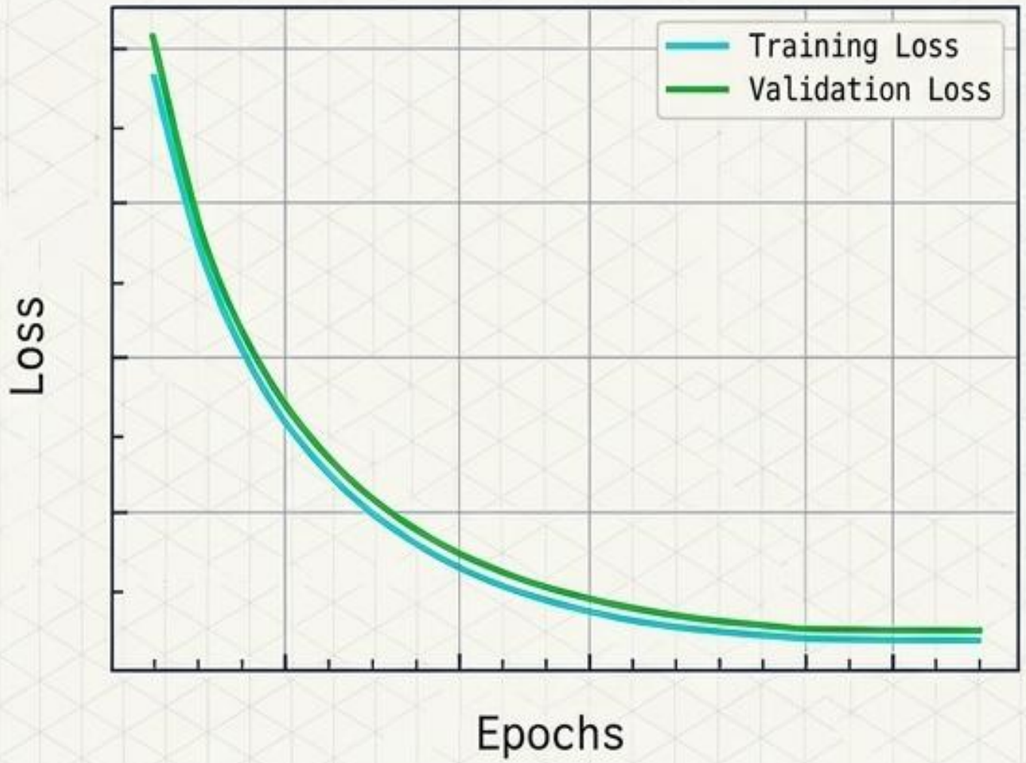
Usamos ECM (mse) para optimizar y EAM (mae - Error Absoluto Medio) porque es interpretable en grados Celsius.

Regla del Baseline: Antes de evaluar la red, **calcula una predicción ingenua** (‘Mañana hará la misma temperatura que hoy’). Si tu LSTM no supera este error mínimo, el modelo no está aprendiendo patrones útiles.

MATRIZ DE DIAGNÓSTICO

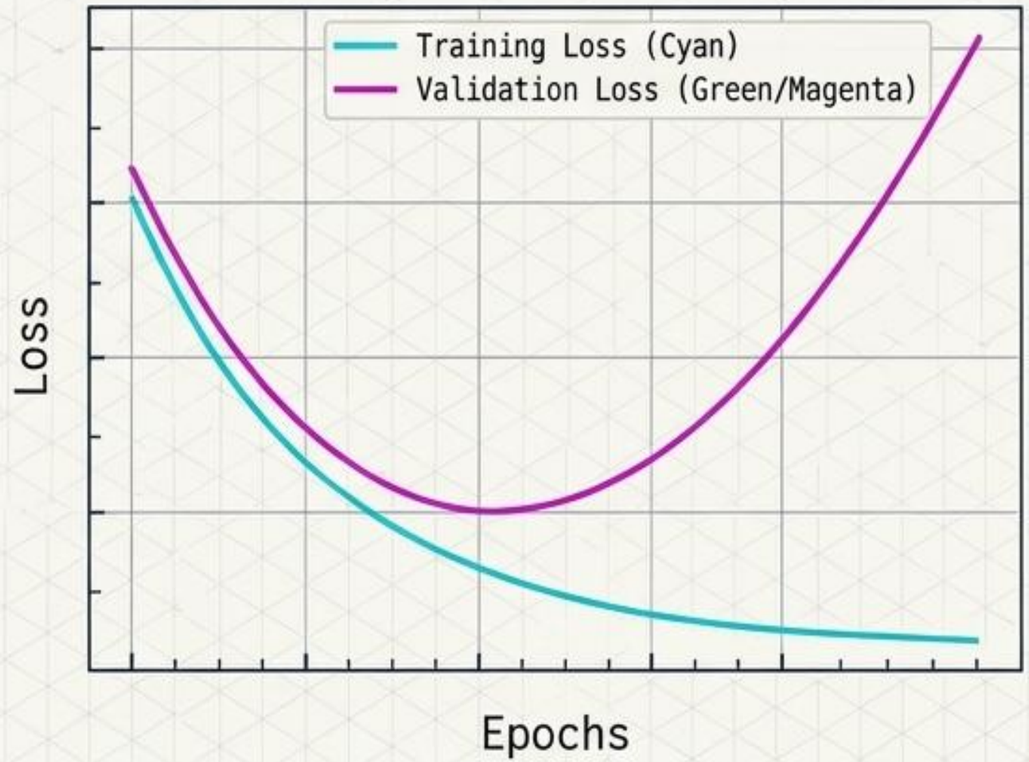
Parámetro	Función en el Sistema	Efecto de Exceso (Muy Alto)	Efecto de Defecto (Muy Bajo)
Epochs	Recorridos del dataset	**Sobreajuste** (memoriza)	**Subajuste** (no aprende)
Batch Size	Muestras por actualización	**Convergencia estable** pero lenta	Entrenamiento rápido pero **caótico/ruidoso**
Learning Rate	Tamaño del paso de ajuste	Salta el mínimo (**no converge**)	Convergencia **excesivamente lenta**
Capacidad (Filtros)	Abstracción de patrones	Cómputo excesivo, **alto sobreajuste**	Representaciones **demasiado simples**

El Ajuste Ideal / Good Fit



Buen Ajuste: El modelo aprende patrones generales. Ambas curvas de pérdida descienden y se estabilizan juntas.

El Sobreajuste / Overfitting



Sobreajuste: El modelo empieza a “memorizar” los datos de entrenamiento y pierde la capacidad de generalizar con datos nuevos.

SOLUCIONES AL SOBREAJUSTE / OVERFITTING SOLUTIONS

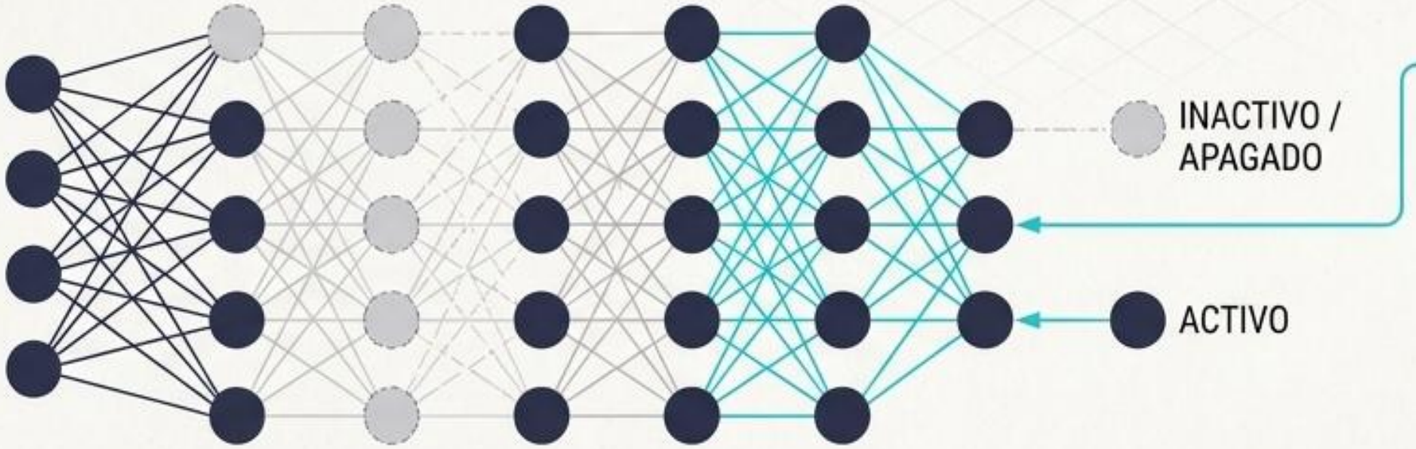
FRENO DE EMERGENCIA: EARLY STOPPING

```
EarlyStopping(
    monitor='val_loss',
    patience=5,
    restore_best_weights=True
)
```



Detiene el entrenamiento automáticamente cuando la pérdida de validación deja de mejorar durante 5 épocas, rescatando los mejores pesos del pasado.

REDUNDANCIA: DROPOUT




```
layers.Dropout(0.3)
```

Apaga aleatoriamente neuronas durante el entrenamiento. Obliga a la red a no depender de una sola conexión y crear representaciones redundantes y robustas.

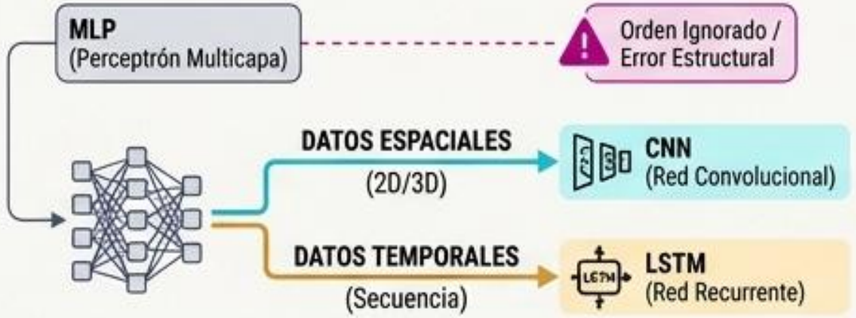
COMPARACIÓN MAESTRA DE ARQUITECTURAS / MASTER ARCHITECTURE COMPARISON

Dimensión	Perceptrón Multicapa (MLP)	Red Convolucional (CNN)	Red Recurrente (LSTM)
Estructura de Entrada	1D (Vectores independientes)	2D (Cuadrículas espaciales)	1D + Tiempo (Secuencias)
Mecanismo Principal	Capas Densas (Pesos globales)	Filtros Compartidos (Kernels)	Estado Oculto (Compuertas)
Caso de Uso en Curso	Dataset tabular Huancayo	Imágenes Fashion-MNIST	Clima histórico Huancayo
Salida Típica	**`sigmoid`** (Binaria)	**`softmax`** (Multiclase)	**`Sin activación`** (Regresión)

PRINCIPIOS DE DISEÑO PARA EL LABORATORIO

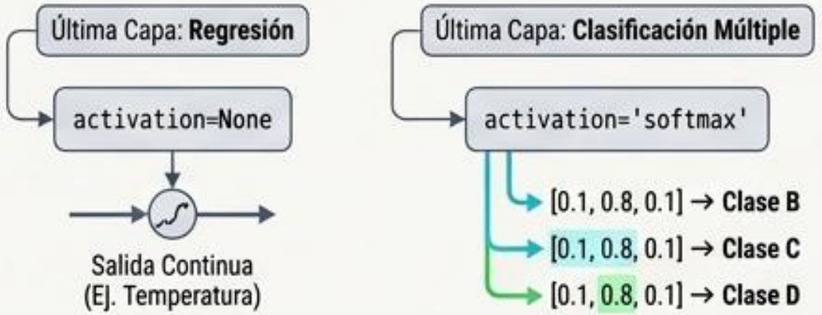
1. La Forma Dicta la Herramienta

Nunca uses un MLP si el orden físico (espacio) o cronológico (tiempo) de los datos importa. Usa CNN o LSTM.



2. El Problema de Salida

Revisa tu última capa antes de compilar. ¿Regresión? Sin activación. ¿Clasificación Múltiple? Softmax.



3. La Regla del Baseline

En series temporales, tu modelo debe ser capaz de ganarle a una predicción ingenua ('mañana será igual que hoy'). Si no, revisa tus datos.



4. Automatiza la Parada

Nunca confíes en un número fijo de epochs. Entrena con un límite alto, pero usa EarlyStopping para frenar en el punto óptimo de generalización.

